



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 浙江工商大学

参赛队号 24103530011

1.张扬泉

队员姓名 2.赵丽蓉

3.冉 熙

中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

题 目：基于 XGBoost 与遗传算法的磁性元件损耗预测研究

摘 要：

磁性元件作为电能转换技术的核心设备，其效率和性能直接关系到我国电网、新能源、通信信息等领域的发展与创新。因此，优化磁性元件的整体性能显得尤为重要。磁芯损耗是由磁性材料在高频交变磁场作用下产生的功率损耗，是影响磁性元件性能的关键因素之一。由于磁芯损耗受多种复杂因素的影响，现有的损耗模型与实际应用需求之间存在较大差距。因此，本文研究励磁波形分类、损耗因素分析和损耗预测等问题，期望建立一种具有广泛适用性和高精度的磁芯损耗模型。

针对问题一，我们首先采用特征变量提取方法，从时域特征、频域特征和波形特征三方面提取磁通密度的关键特征变量，并对提取的特征变量进行数据预处理，利用 PCA 方法降维，以保留数据重要特征，降低数据维度，为分类模型的训练奠定基础。在数据准备完成后，我们将数据集划分为 80% 的训练集和 20% 的测试集，以用于分类模型的训练与评估。我们对比了 RandomForest、SVM、KNN、DecisionTree、GradientBoosting、LogisticRegression、NaiveBayes、XGBoost 八种分类模型在励磁波形分类问题上的均方误差、召回率等反应模型性能和有效性的指标。最终，选择精确率为 98.96%，分类均方误差仅为 0.0125 的 XGBoost 作为最终的励磁波形分类模型，并利用该模型对附件二中的样本进行波形分类。

针对问题二，我们首先使用最小二乘法对四种材料在正弦波形下的斯坦麦茨方程参数进行求解，并基于所得方程预测磁芯元件的损耗。通过比较不同温度条件下的预测误差，初步探索了温度对斯坦麦茨方程预测精度的影响。随后，我们基于温度对斯坦麦茨方程预测结果的影响进行方程修正，通过函数拟合法，探索温度因素在方程中的最佳修正形式，旨在引入温度因素后最小化预测误差。结果表明，当温度以二次函数和三次函数形式进行修正时，方程的预测效果最好，且以二次函数形式进行修正后的方程为 $P_{new} = -0.166320 \cdot f^{1.466724} \cdot B_m^{2.450911} \cdot (-0.000720 \cdot T^2 + 0.128109 \cdot T - 11.324206)$ 。经过修正，斯坦麦茨方程在磁芯损耗预测中的均方误差相较标准方程缩小了近 12 倍，平均绝对误差、均方根误差以及平均百分比误差也得到大幅改善，证明基于温度因素的斯坦麦茨方程修正有效。

针对问题三，我们首先通过**统计分析和相关性分析**，探讨了温度、励磁波形和磁芯材料三个因素对磁芯损耗的独立影响。结果显示，励磁波形对磁芯损耗的独立影响相较于其他因素更为显著。接着，我们采用**特征乘积的形式**构建温度、励磁波形和磁芯材料的两两交互特征，分析各自变量之间的协同作用。在此基础上，利用**随机交互森林模型**对特征重要性进行了分析，综合探讨材料、励磁波形、温度及其交互项对磁芯损耗的影响。研究结果表明，励磁波形的特征重要性最高，而温度与励磁波形的交互作用对磁芯损耗的特征重要性最低。最后，通过建立优化模型，我们进一步探索了磁芯损耗最小化的条件。在有限的约束条件组合下，对不同组合的磁芯损耗均值进行排序，并**可视化两两因素组合热力图**，得出**磁芯材料 4，在温度为 90℃ 和正弦波形下损耗最小**。

针对问题四，我们借助问题一中的特征选择和数据预处理结果，构建了 **XGBoost 回归预测模型**，用于解决跨越材料类型与工况条件的磁芯损耗预测问题。在误差与精度评估中，我们将 XGBoost 模型的预测结果与斯坦麦茨方程及其修正方程，以及其他机器学习和深度学习模型进行了对比。结果表明，XGBoost 模型的预测误差显著低于传统模型和其他机器学习模型，验证了其在预测精度上的优越性。为进一步保证模型的**泛化能力**，我们采用了**5 折交叉验证策略**，结果显示模型在多次验证中的 MSE 和 RMSE 表现稳定，一致性较好，进一步证明了 XGBoost 模型的良好泛化能力。综合以上分析，XGBoost 回归预测模型可作为磁芯损耗预测的有效工具，并用于对附件三中样本的磁芯损耗进行预测。与此同时，我们还构建的磁芯损耗预测模型在业界的实际应用，为生产实践提供指导建议。

针对问题五，我们首先构建了磁性元件整体性能最优化的**多目标规划模型**，以磁芯损耗最小化和传输磁能最大化为目标函数，约束条件为各决策变量的类型及其取值范围。随后，采用**目标比值法**将多目标规划转化为**单目标规划**，并使用适用性较强的**遗传算法**进行求解。最终结果表明，温度条件为 **81.86℃**，频率为 **61737.12 Hz**，磁通密度峰值为 **0.3041 T**，波形为**正弦波**，磁芯材料为材料 1 时，达到最小的磁芯损耗 **$P=28.3151 \text{ W/m}^3$** ，以及最大的传输磁能 **18776.6684 J**，此时实现磁性元件整体性能的最优化。

最后，我们对算法有效性、复杂性及模型稳定性、灵敏性进行分析，总结了模型的优缺点，并提出未来改进方向。

关键词： XGBoost；遗传算法；随机交互森林模型；目标优化；特征提取；非线性回归

目录

1 问题重述.....	5
1.1 问题背景.....	5
1.2 问题提出.....	6
2 问题分析.....	7
2.1 问题一分析.....	7
2.2 问题二分析.....	7
2.3 问题三分析.....	7
2.4 问题四分析.....	8
2.5 问题五分析.....	8
3 模型假设与符号说明.....	10
3.1 模型假设.....	10
3.2 符号说明.....	10
4 问题一：励磁波形分类模型建立与求解.....	11
4.1 特征变量提取.....	11
4.2 分类模型建立.....	13
4.2.1 数据预处理.....	13
4.2.2 XGBoost 等分类模型训练	14
4.2.3 模型评估与选择.....	16
4.3 分类结果展示.....	18
5 问题二：斯坦麦茨方程的修正.....	19
5.1 斯坦麦茨方程效果分析.....	19
5.1.1 斯坦麦茨方程系数拟合.....	19
5.1.2 效果分析.....	19
5.2 基于温度影响的斯坦麦茨方程修正.....	22
5.3 基于温度的 N 次函数斯坦麦茨方程修正效果对比.....	23
6 问题三：磁芯损耗因素分析.....	25
6.1 因素独立作用分析.....	25
6.2 交互协同对磁芯损耗影响模型.....	29
6.2.1 交互项特征构造.....	29
6.2.2 相关性分析.....	29
6.2.3 随机交互森林（RIF）模型	31
6.3 最小磁芯损耗的因素选择模型.....	32
7 问题四：基于数据驱动的磁芯损耗预测模型.....	35
7.1 XGBoost 回归预测模型	35
7.2 模型效果分析.....	36
7.2.1 预测精度分析.....	36
7.2.2 泛化能力分析.....	38
7.3 求解结果.....	38
7.4 业界指导建议.....	39
8 问题五：磁性元件的最优化条件.....	43
8.1 最优化模型建立.....	43
8.1.1 确定变量和取值范围.....	43

8.1.2 构建目标函数.....	43
8.1.3 定义约束条件.....	43
8.2 遗传算法求解.....	44
9 模型评价与改进.....	46
9.1 算法有效性与复杂性分析.....	46
9.2 模型稳定性与灵敏度分析.....	46
9.3 优点分析.....	46
9.4 缺点分析.....	47
9.5 模型改进.....	47
参考文献.....	48
附录.....	49

1 问题重述

1.1 问题背景

近年来,随着电力电子技术的发展,电能变换技术的应用逐渐成熟。电能变换技术通过 AC/DC、DC/DC、AC/AC 等方式实现能量传递、储存和变换,极大提升了系统的效率和可靠性,同时推动了现代工业和新能源技术的发展,目前被广泛应用于电网、新能源、电动汽车、信息通讯设备和消费电子产品等重要领域。作为实现电能变换技术的核心设备,功率变换器随着新能源和信息通信技术的迅猛发展,面临着处理更高功率密度、更高频率以及更高效率需求的挑战,这也推动了功率变换器的不断创新。而磁性元件(如变压器、电感)是功率变换器的核心组成部分之一,在能量的传输、存储和转换中起到关键作用。功率变换器通过磁性元件完成电能的变压、变频、滤波等功能,确保电能高效稳定地转换,因此,磁性元件的设计和性能对功率变换器的效率、体积、重量和成本有显著影响。选择合适的磁性材料和优化设计,不仅可以提高能量转换效率,还可以有效减少设备的体积和重量,但不当的设计会导致过高的损耗,从而影响系统的效率。

磁性元件的损耗问题往往会对其设计方案和应用场景等方面产生影响,所以掌握磁性元件的工作机理,熟悉其损耗机制,了解影响损耗的相关因素变得至关重要。磁性元件工作产生的损耗主要包括绕组损耗和磁芯损耗两部分。绕组损耗是电流流经磁芯绕组时的热量损失,由于铜是磁芯绕组的主要成分,故绕组损耗又称为铜损^[1];而磁芯材料自身结构复杂,在高频应用中产生的磁芯损耗与温度、频率、励磁波形、材料等众多因素相关,且相互影响呈现非线性特征,目前现有模型与实际应用的差异较大,因此,磁芯损耗是磁性元件中不可忽视的重要问题,也成为了影响功率变换器效率的主要因素之一,是本文的主要研究对象。

目前已知,磁芯损耗模型分为两种:损耗分离模型和经验计算模型。根据 Bertotti 磁芯损耗构成理论可知,磁芯损耗 P_v 主要由磁滞损耗 P_h 、涡流损耗 P_c 和剩余损耗 P_{ex} 三部分组成^[2],即 $P_v = P_h + P_c + P_{ex}$ 。其中,磁滞损耗是由于磁性材料在交变磁场中不断被磁化和去磁化时,损失的一部分被转化为热量的能力;涡流损耗是在交变磁场中,磁场的变化会在磁芯内部感应出环形电流(即涡流),涡流会在磁芯材料中循环而产生的电阻性损耗;而剩余损耗则是由磁性材料的复杂微观结构引起的损耗,通常表现为高频条件下的非线性损耗。经验计算模型是通过实验或推导得出经验公式来估计磁芯损耗,该方法在应用计算中更为简洁。最具代表性的磁芯损耗经验公式为斯坦麦茨方程,方程总结了正弦波励磁下,磁芯损耗 P 取决于频率 f 和磁通密度峰值 B_m 的幂函数。随后, Rudy^[3]和 Venkatachalam^[4]等人将斯坦麦茨方程进行修正,得出任意波形励磁下磁芯损耗的经验计算公式。从这些经验公式中可以看出,磁芯损耗与磁芯材料、温度、频率、励磁波形、磁通密度峰值等因素均有关系,但目前还未有适用性高且精读良好的模型来评估实际应用中的磁芯损耗。在此背景下,本文将基于实验场景和给定的集采数据,运用数学及算法模型,建立普遍适用的高精度磁芯材料损耗模型,并通过测试数据检验模型精确度,为磁芯损耗的评估提供理论参考。

1.2 问题提出

为解决磁性元件磁芯损耗精确评估问题，研究采用交流功率法来测量磁芯损耗值，使用绕制励磁绕组和感应绕组的圆环形磁芯，通过信号发生器和高频功率放大器生成磁场强度和磁通密度，采集励磁电流和感应电压来计算磁芯损耗密度，并给出了 4 中不同材料，在不同工况下的磁芯损耗值和一个周期时间内的磁通密度。本文运用实测的不同温度、频率、磁通密度下的磁芯损耗数据，建立数学模型分析、预测、优化如下问题。

问题一：励磁波形分类模型

根据附件一中的磁通密度数据，首先通过分析三种励磁波形（正弦波、三角波、梯形波）磁通密度在周期内随时间的分布特征，针对不同的波形提取出能够反应它们波形形状的特征变量，作为分类模型的输入数据；其次，选择适当的分类算法，基于提取出的特征变量建立励磁波形分类模型，并根据模型分类的分类效果来分析分类模型的合理性和有效性；最后基于已建立的分类模型对附件二中样本的励磁波形进行分类识别，将分类结果填入的附件四的 Excel 表格中，并统计附件二分类结果中三种励磁波形的数量。

问题二：斯坦麦茨方程的修正

根据斯坦麦茨方程及其仅适用于正弦波励磁的局限性，首先，基于附件一同一种磁芯材料、正弦波形下的磁芯损耗数据，分析不同温度变化对于标准斯坦麦茨方程在磁芯损耗预测效果上的影响；其次，分析温度影响效果，构建带有温度修正项的斯坦麦茨磁芯损耗模型，该模型通过增加温度因素，提升修正后的斯坦麦茨方程对于不同温度变化下磁芯损耗预测结果的精准度；最后以附件一正弦波形数据为例，对比修正前与修正后的斯坦麦茨方程在预测磁芯损耗效果上的误差，确保模型有效性。

问题三：磁芯损耗因素分析

由于在众多磁芯损耗影响因素中，磁芯材料、温度和励磁波形被认为是最重要的三大因素，因此本问题将针对这三大因素对磁芯损耗的影响进行深入分析。根据附件一中的数据，首先分析磁芯材料、温度和励磁波形分别对磁芯损耗的独立影响；随后，在独立影响的基础上，分析磁芯材料和温度、磁芯材料和励磁波形、温度和励磁波形两两因素对磁芯损耗的协同影响；最后需要对影响程度进行定量分析，得出在磁芯材料、温度和励磁波形不同条件组合下的最低磁芯损耗的组合。

问题四：基于数据驱动的磁芯损耗预测模型

由于现存磁芯损耗预测模型在精度及适用性上存在缺陷，本题中要求建立一个跨越材料类型与工况条件的磁芯损耗预测模型，以此优化磁性元件性能。首先，基于附件一的实验数据，选择合适的预测模型进行训练求解，并评估模型效果；其次，需要使用不同的测试集来评估模型的泛化能力，检验模型在新数据上是否依然能够保持较好的预测效果；最后运用所构建的磁芯损耗预测模型对附件三的样本数据进行磁芯损耗预测，并将结果填入附件四的 Excel 表格中。

问题五：磁性元件的最优化条件

本问题要求同时考虑磁芯损耗和传输磁能两项指标，以问题四建立的磁芯损耗预测模型为目标函数，建立优化模型，求解得到在怎样的磁芯材料和工况条件下能使磁芯损耗最小化的同时具有最大的传输磁能。

2 问题分析

基于题目所提供的不同磁性材料在不同工况下的磁芯损耗和磁通密度变化数据，结合当前对于磁性元件损耗预测的相关研究模型与结果，我们针对题目给定的上述五个问题进行了如下解释与分析：

2.1 问题一分析

为了利用附件一中的磁通密度数据对励磁波形进行分类，我们首先需要对附件一中不同励磁波形的磁通密度数据进行特征提取，通过从时域特征、频域特征和波形特征三方面提取具有代表性的数值特征作为特征变量，为构建了精准的励磁波形分类模型做初步准备。随后，还需要对提取的特征变量数据进行数据预处理，使数据更适用于分类模型的训练与测试。在分类模型训练过程中，为了得到更加适用于励磁波形分类问题的模型，我们需要对比了目前较为常见的分类模型，大致包括 RandomForest、SVM、KNN、DecisionTree、GradientBoosting、LogisticRegression、NaiveBayes、XGBoost 等，并通过模型评估比较不同分类模型的效果，选择出效果最佳的励磁波形分类模型，并使用该模型对附件二中的样本进行波形的识别与分类。

2.2 问题二分析

已知斯坦麦茨方程仅适用于正弦波励磁下，对同一种材料的磁芯损耗预测，其参数主要包括磁通密度、频率和材料的物理特性。然而，该方程未考虑温度因素对预测效果的影响。题目要实现基于温度因素的斯坦麦茨方程修正，首先需要探索温度因素是如何影响斯坦麦茨方程的预测效果的。具体而言，我们首先需要基于附件一中同一种材料在正弦波下的实验数据，对斯坦麦茨方程的参数进行拟合，以得到该材料的斯坦麦茨方程。然后，使用拟合后的方程对磁芯损耗进行预测，比较不同温度下的预测误差，以探索温度对斯坦麦茨方程预测结果的影响效应。我们将基于温度对斯坦麦茨方程预测结果的影响进行修正。通过函数拟合法，探索温度影响因素的最佳修正形式，并将其引入标准斯坦麦茨方程，使得预测误差最小。最后，选用均方误差、平均绝对误差等误差统计指标对修正前后的斯坦麦茨方程预测效果进行全面评估，以证明修正方程的有效性。

2.3 问题三分析

为了分析影响磁芯损耗的因素，首先需要探究温度、磁芯材料和励磁波形三个单因素对磁芯损耗的独立影响以及三个单因素自变量之间的相互影响程度。具体而言，需要对温度、磁芯材料和励磁波形与磁芯损耗的关系进行探索性分析、相关性分析，并在此基础上进行回归分析。题目还要求我们分析温度、磁芯材料和励磁波形两两之间的协同作用对磁芯损耗的影响。我们将基于协同作用构建交互项特征，通过相关性分析，探究自变量以及交互项和磁芯损耗的关系，评估影响程度。通过相关性分析发现各个特征之间的多重线性关系后，采用特征重要性提取法进行量化指标分析，可能使用的方法有线性回归、多项式回归、岭回归、随机森林交互法等。最后，为了实现磁芯损耗最小化问题，需要建立单目标规划模型，以磁芯损耗最小化为目标，决策变量的类型作为模型约束条件，建立磁芯损耗优化模型。在温度仅考虑 4 种类型的情况下，我们发现约束条件的总组合数有限，于是可以通过不同条件组合下的磁芯损耗均值（从小到大排序）分析得到磁芯损耗最小的结果，

并通过可视化两两因素组合热力图来展示最优损耗时的温度、磁芯材料和励磁波形的条件。

2.4 问题四分析

要构建基于数据的磁芯损耗预测模型，首先要识别这是一个多元非线性回归预测问题，选择合适的模型是首先要完成的。结合第二问的经验，XGBoost 模型可能对本问题的数据匹配性更高，拟作为优先编程实现的算法模型，其中需要注意有附件一特征变量具有 18 个维度，必须完成主成分分析（PCA 降维）才能获得误差较小的回归结果。完成模型的构建后题目要求对模型进行精度和泛化能力分析，精度分析主要通过模型对比来回答，例如和问题二的修正公式，其他机器学习算法甚至是深度学习算法。泛化能力主要体现在对测试集的准确率和误差上，对没见过的工况预测得准泛化能力就好，可以通过多折交叉验证和测试集与训练集误差幅度来体现。最后可以开发一些脚本来完成最终预测模型的保存，调用，以及测试集的预测和写入保存，都通过 Python 实现即可。

2.5 问题五分析

为了实现磁性元件整体性能最优化问题，需要建立双目标规划模型，以磁芯损耗最小化和传输磁能最大化共同作为目标函数，决策变量的类型及取值范围作为模型约束条件，建立磁性元件性能优化模型。对于多目标规划问题的求解，考虑加权和法和目标比值法对多目标问题进行转化，期望得到单目标模型简化后续的求解。在模型求解中，由于决策变量为混合变量（包含离散变量和连续变量），因此，选取适用性较强的遗传算法进行求解，以得到磁性元件整体性能最优化的条件。

2.6 全文技术路线

全文技术路线图如下图 2-1 所示：




图 2-1 全文技术路线图

3 模型假设与符号说明

3.1 模型假设

假设 1：温度为离散类别数据，在问题三中，温度并不是一个连续变化的变量，而是具有固定的离散值。我们假设在实验和实际应用中，温度只取四个特定值，并在这些温度条件下进行磁芯损耗的分析和优化，而不考虑温度在其他范围内的变化。

假设 2：假设温度、磁芯材料、励磁波形三个变量之间不同时存在三者相互的协同作用，即三者共同协同作用于磁芯损耗。

假设 3：实验数据本身不存在错误，即所有数据不存在人为记录错误，原始测量值均准确，都是符合物理规律的数据。

3.2 符号说明

表 3-1 符号说明表

符号	符号描述
B	磁通密度
f	频率
P	磁芯损耗
B_m	磁通密度峰值
T	温度
W	励磁波形
M	磁芯材料
E	传输磁能
$P_{\max}$	磁芯损耗的最大值
$E_{\max}$	传输磁能的最大值

4 问题一：励磁波形分类模型建立与求解

4.1 特征变量提取

特征提取是从原始数据中提炼出对数据特性有显著代表性的信息，供机器学习模型用于训练和预测，其目的是筛选出对模型有价值的特征，从而提升模型整体的预测性能和计算效率。对于本问题中磁通密度的特征提取，我们基于数据的周期性特征，从时域特征、频域特征和波形特征三方面来提取不同波形的特征。

1. 时域特征

时域特征是直接从时间序列数据中提取的统计特征，反映的是数据在时间维度上的变化情况。本问题基于磁通密度随时间的变化主要提取如下特征变量：

- **最大值/最小值（峰值）**：波形的最大值和最小值能区分波形的幅度特性。正弦波、三角波和梯形波的峰值位置和高度可能不同。

$$\begin{aligned}\text{Max}(B) &= \max(B_1, B_2, \dots, B_n) \\ \text{Min}(B) &= \min(B_1, B_2, \dots, B_n)\end{aligned}\quad (1)$$

- **均值**：不同波形的均值可能会有差异，正弦波的均值接近于零，三角波的均值也接近零，而梯形波可能更接近某一固定值。

$$\mu_B = \frac{1}{n} \sum_{i=1}^n B_i \quad (2)$$

- **标准差（或方差）**：反映波形振动的离散程度，不同波形的波动幅度差异较大。

$$\sigma_B = \sqrt{\frac{1}{n} \sum_{i=1}^n (B_i - \mu_B)^2} \quad (3)$$

- **幅值**：最大值与最小值之差，体现波形的整体振幅变化。

$$\text{P-P}(B) = \text{Max}(B) - \text{Min}(B) \quad (4)$$

- **偏度和峰度**：用于反映波形的对称性（偏度）和尖锐度（峰度）。

$$\text{Skewness}(B) = \frac{\frac{1}{n} \sum_{i=1}^n (B_i - \mu)^3}{\sigma^3} \quad (5)$$

$$\text{Kurtosis}(B) = \frac{\frac{1}{n} \sum_{i=1}^n (B_i - \mu)^4}{\sigma_B^4} - 3$$

2. 频域特征

频域特征是通过分析磁通密度随时间变化的数据在频率维度上的特性而提取的，捕捉频率特性能够揭示其振动模式和能量分布，对机器学习分类模型提供有用的信息频域特征。但频域特征的提取过程需要将所得数据从时域转换到频域，最常用的方法是傅里叶变换，如公式（6）所示。

$$B(f) = \int_{-\infty}^{\infty} B(t) e^{-j2\pi ft} dt \quad (6)$$

其中， $B(t)$ 表示时域值，表示周期时间 t 上的磁通密度； $B(f)$ 表示傅里叶变换后的磁通密度频率分量； f 表示频率； $e^{-j2\pi ft}$ 表示频率为 f 的正弦波。傅里叶变换将时域中的随周期

变化的磁通密度分解为多个具有特定频率、幅度和相位的正弦波形，使我们更容易地理解磁通密度分布的频率特性，本题通过分析提取得到如下四项磁通密度的频域分布特征：

- **总能量：**总能量表示的是转换后的磁通密度频率分量在频域中所有频率成分的能量累积。不同的励磁波形，其总能量大都有显著差异，因此总能量能够帮助我们较为有效的区分励磁波形。

$$E_{\text{total}} = \sum_{k=1}^n |B(f_k)|^2 \quad (7)$$

- **主频率：**主频率是所有频谱中能量最强的，也是幅度最大的磁通密度频率分量，不同的励磁波形可能具有不同的主频率，有助于识别磁通密度频域中的主要振动模式促进波形分类。

$$f_{\text{dominant}} = \arg \max_{f_k} |B(f_k)| \quad (8)$$

- **前 10 个频率成分的能量之和：**前面主频率提取了所有频谱中能量最强的磁通密度频率分量，而该特征提取则计算了能量前十的磁通密度频率分量的总能量，能够更加全面的描述磁通密度频谱的主要频率成分能量。

$$E_{10} = \sum_{k=1}^{10} |B(f_k)|^2 \quad (9)$$

- **频谱能量分布的标准差：**频谱能量分布的标准差能够展示磁通密度频率分布的离散程度。不同的励磁波形在频率分布的离散程度中差异较大，例如，正弦波的频率分布较为集中，而三角波或梯形波的频率分布较为分散。

$$\sigma_E = \sqrt{\frac{1}{N} \sum_{k=1}^n (f_k - \mu_f)^2 |B(f_k)|^2} \quad (10)$$

其中， μ_f 为整个磁通密度频谱的加权平均频率 $\mu_f = \frac{\sum_{k=1}^N f_k |X(f_k)|^2}{\sum_{k=1}^N |X(f_k)|^2}$ 。

3. 波形特征

励磁波形分模型的特征提取中除了常见的时域特征和频域特征外，还可以考虑从磁通密度波形中提取有用的特征。不同的励磁波形会导致磁通密度呈现不同的波动模式，因此，提取与磁通密度波形形状相关的特征变量，将有助于准确区分三种波形。

- **梯度变化率：**梯度变化率反映磁通密度随时间的变化速度，不同波形的变化速率不同。例如，梯形波有明显的快速上升和平坦段，而正弦波是平滑的变化。

$$\Delta B = \frac{dB}{dt} = \frac{B(t) - B(t-1)}{t - (t-1)} \quad (11)$$

- **零交叉点：**零交叉点表示磁通密度从正值到负值或从负值到正值的过渡次数。不同波形在一个周期内的零交叉点数量不同，可以帮助周期性区分励磁波形。

$$N_{\text{Zero}} = \sum_{i=1}^{n-1} \mathbb{1}(B[i] \cdot B[i+1] < 0) \quad (12)$$

其中， $\mathbb{1}$ 为指示函数，当磁通密度发生零交叉时值为 1，否则值为 0。

- **总面积：**总面积特征表示磁通密度波形在一个周期内相对于时间轴的总面积。不同波形由于形状差异，其面积特征也会有所不同。

$$S = \int_{t_0}^{t_N} |x(t)| dt \quad (13)$$

综上所述，在建立励磁波形分类模型时，我们首先针对不同波形在磁通密度分布上的差异，提取了如图 4-1 所示的磁通密度特征变量。该步骤将数千个磁通密度数据点精简为少量具有代表性的数值特征，基于这些提取的特征变量，我们将进一步构建了精准的励磁波形分类模型。




图 4-1 磁通密度特征变量分类树状图

4.2 分类模型建立

4.2.1 数据预处理

- 标签编码

在处理励磁波形这种分类数据时，特征编码将非数值型的分类变量转化为数值型，方便了机器学习模型的识别和处理。本研究中，将励磁波形类别为“正弦波”、“三角波”、“梯形波”分别编码为 0, 1, 2，为后续模型训练作准备。

- 数据标准化

由于所提取的磁通密度特征变量取值范围的差异很大，可能会导致磁通密度特征变量值较大的特征主导模型的学习过程，导致模型倾向于这些特征，影响励磁波形分类模型的训练效果。因此，为了使各个磁通密度特征变量对模型有较为均衡的影响，我们需要采用数据标准化的方法对磁通密度特征变量进行缩放，数据标准化公式如下：

$$z = \frac{x - \mu}{\sigma} \quad (14)$$

其中， μ 表示磁通密度特征变量的均值， σ 表示标准差。

- **PCA 降维**

由于磁通密度特征变量的维度较大，增加了模型训练的时间与复杂度，并且可能导致模型过拟合或者欠拟合，所以我们采用主成分分析（PCA）^[5]的方法来降低数据的维度，同时尽可能保留大部分磁通密度特征变量的原始信息，确保励磁波形分类模型的训练效果不会因为降维而显著受损。PCA 降维主要分为以下几步：

（1）数据中心化：用每个磁通密度特征变量减去其均值，确保数据分布的均值为零。

$$Z_c = z_i - \mu_B \quad (15)$$

（2）计算协方差矩阵：协方差矩阵用来表示磁通密度各特征变量之间的线性关系。

$$\text{Cov}(Z) = \frac{1}{n-1} Z_c^T Z_c \quad (16)$$

（3）特征值分解：对上述协方差矩阵进行特征值分解，得到其特征值和对应的特征向量。

$$\text{Cov}(Z)v_i = \lambda_i v_i \quad (17)$$

其中， λ_i 是特征值， v_i 是对应的特征向量。

（4）选择主成分：根据特征值的大小选择主成分，特征值越大，对应的主成分携带的数据方差信息越多。本题我们设置保留方差比例为 95%，即选择最少数量的主成分，使得这些主成分能够解释原始数据 95%的方差信息。

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^N \lambda_i} \geq 0.95 \quad (18)$$

（5）数据投影：将磁通密度特征变量从高维空间映射到上述主成分构成的低维空间，即用中心化数据矩阵乘以主成分矩阵，最终实现数据降维。

$$Z_r = Z_c V_k \quad (19)$$

其中， V_k 是特征向量矩阵，每一列是一个特征向量，对应一个主成分。经过如上预处理的数据已具备了较优的特性，将用做接下来分类模型的训练与测试。

4.2.2 XGBoost 等分类模型训练

分类模型是指将过去已经分类好的类别数据给到机器，让它学习和训练，从而可以预测新数据的类别。主要适用于信用评分、垃圾邮件预测、医疗诊断、用户行为预测等场景中。在励磁波形分类问题中，我们需要建立一个高效、准确的模型来识别不同的励磁波形类型，因此我们对比了目前较为常见的分类模型包括 RandomForest、SVM、KNN、DecisionTree、GradientBoosting、LogisticRegression、NaiveBayes、XGBoost，期望选择出最适合于励磁波形分类问题的模型。

RandomForest（随机森林）的核心思想是通过多次随机抽样，构建多个独立的决策树模型。每棵决策树在训练时随机选择一部分样本和特征进行学习，从而

保证了模型的多样性和稳健性。最终的分类结果通过所有决策树的投票机制决定。在本题励磁波形分类中，随机森林通过对提取的时域、频域和形状特征进行随机采样，生成多个决策树，最终通过投票机制确定样本的分类结果及分类置信度。

SVM（支持向量机）通过寻找能够最大化类别间距的最优超平面，将样本分为不同的类别。它不仅适用于线性可分的数据，还可以通过核函数将数据映射到更高维的空间，从而处理线性不可分的情况。在本问题中，励磁波形的特征较为复杂，SVM 的核方法能够帮助我们捕捉这些复杂的非线性关系。我们将提取的时域、频域和形状特征输入 SVM 模型。根据这些特征，SVM 构建一个能够最大化不同波形类别（正弦波、三角波、梯形波）之间的超平面。对于特征间存在非线性关系的部分，SVM 通过核函数方法将其映射到更高维度进行处理，从而提高分类效果。

KNN（K 近邻算法）是一种简单且有效的非参数分类方法。KNN 通过计算待分类样本与训练样本之间的距离，选择与其最接近的 K 个邻居，根据这些邻居的类别进行分类。在励磁波形分类中，我们将提取的时域、频域和形状特征作为输入，通过 KNN 算法对这些特征进行分类。具体来说，对于每个待分类的波形特征向量，KNN 首先计算它与训练集中其他样本的距离，选择 K 个最接近的波形作为参考，并根据这些邻居所属的类别进行分类。

Decision Tree（决策树）是一种常用的分类模型，其通过对特征空间进行逐步划分，构建一系列的决策规则，其中每个节点表示对某一特征的判断或分裂，每一次分裂将数据集划分为更纯的子集，直到达到预设的停止条件。在励磁波形分类中，我们使用提取的时域、频域和形状特征作为决策树的输入。决策树通过不断划分这些特征，构建一个分层的决策过程，以便对正弦波、三角波和梯形波进行分类。每个分裂点都会基于某个特征的阈值，逐步将样本归类到相应的叶节点，叶节点即代表最终的波形类别。

Gradient Boosting（梯度提升）是一种强大的集成学习算法，通过逐步构建一系列弱分类器，将多个弱分类器（如决策树）逐步叠加在一起，使得每个新加入的分类器都能修正前一轮的分类误差，从而使每个分类器的错误率最小化。在励磁波形分类问题中，我们利用梯度提升模型对提取的时域、频域和形状特征进行分类。每次模型通过残差调整权重，逐步优化分类结果。梯度提升在处理励磁波形中的复杂特征时，能够通过多轮迭代，逐渐捕捉这些特征之间的非线性关系，从而提高对正弦波、三角波和梯形波的分类准确性。

Logistic Regression（逻辑回归）是一种常用的线性分类模型，主要用于处理二分类问题。尽管它是一种线性模型，但通过使用 Sigmoid 函数将输出值映射到概率空间，使其能够适应分类任务。在励磁波形分类问题中，逻辑回归通过对提取的时域、频域和形状特征进行线性组合，计算样本属于正弦波、三角波或梯形波的概率。通过使用多元逻辑回归，模型能够同时处理三类波形，最终输出每个样本属于各类波形的概率，选择最高概率的类别作为分类结果。

Naive Bayes（朴素贝叶斯）是一种基于贝叶斯定理的分类方法，假设特征之间相互独立。尽管这一假设在实际问题中可能并不完全成立，但朴素贝叶斯由于其计算效率和鲁棒性，仍然是处理高维数据时非常有效的分类算法。它通过计算每个类别的条件概率，选择概率最大的类别作为分类结果，适合用于励磁波形的分类任务。在励磁波形分类问题中，我们将提取的时域、频域和形状特征作为输入，使用朴素贝叶斯模型进行分类。对于每个样本，模型通过计算在正弦波、三角波和梯形波类别下，特征的条件概率，得出每个类别的后验概率，并选择后验概率最大的类别作为分类结果。

XGBoost（eXtreme Gradient Boosting）是一种增强版的梯度提升决策树算法，特别适用于处理高维数据和复杂特征组合的分类任务，其核心思想是通过构建多个决策树模型，逐步优化预测误差。XGBoost 通过加权调整每棵树的结果，最终综合各个弱分类器的预测，

得到一个更为强大的模型。XGBoost 相比传统的梯度提升算法，具有以下几个特点：

(1) 正则化：XGBoost 在目标函数中加入了正则化项，能够有效避免过拟合。

(2) 分裂准则优化：通过精确的分裂策略（例如贪婪算法），XGBoost 可以在训练中快速找到最佳分裂点。

(3) 支持并行计算：XGBoost 可以通过并行化处理树结构的构建，大幅提高训练速度。

在励磁波形分类问题中，我们的目标是基于从时域、频域以及形状特征提取的变量，准确识别出正弦波、三角波和梯形波。由于这些特征可能存在高度非线性和复杂的交互关系，XGBoost 模型能通过构建多层决策树捕捉这些复杂模式。

具体流程如下：

Algorithm 1 基于 XGBoost 的励磁波形分类

- 1: **输入：** 训练数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，待分类样本 x 。
 - 2: **输出：** 样本 x 的类别 y 。
 - 3: **步骤：**
 - 4: **初始化模型：**
 - 5: 设定树的数量 T ，学习率 η 和最大深度 d 。
 - 6: **构建第一棵树：**
 - 7: 初始模型预测所有样本的平均值作为第一棵树的预测值。
 - 8: **计算损失函数：**
 - 9: 使用均方误差 (MSE) 作为目标函数，计算预测值与真实标签之间的误差。
 - 10: **更新梯度：**
 - 11: 计算当前梯度 $g_i = \frac{\partial L}{\partial y_i}$ ，并根据梯度调整样本的权重。
 - 12: **生成下一棵树：**
 - 13: 基于更新的梯度构建新的一棵树，逐步优化损失函数。
 - 14: **重复执行 8-13：**
 - 15: 继续生成新的决策树，直到构建 T 棵树，模型收敛。
 - 16: **样本分类：**
 - 17: 最终，使用模型对样本 x 进行分类预测，输出类别 $y = \operatorname{argmax}_c P_c(x)$ ，其中 $P_c(x)$ 是样本属于类别 c 的概率。
 - 18: **输出分类置信度：**
 - 19: 根据分类模型的输出概率值，计算样本分类的置信度 p_c ，即该样本属于某类的概率。
-

基于上述八种分类模型，我们需要将预处理后的数据集划分为训练集和测试集来检验模型效果，训练集用于训练模型，而测试集则用于验证模型在未见数据上的表现。我们使用常见的 **train_test_split** 方法进行数据集划分，`test_size=0.2`，即将 20% 的数据划分为测试集，其余 80% 用于训练模型，并对各模型分类结果精确度进行评估对比。

4.2.3 模型评估与选择

在励磁波形分类任务中，为了评估分类模型的性能和有效性，我们选取以下常见的统计指标：召回率 (Recall)、精确率 (Precision)、F1 分数 (F1-score)、以及均方误差 (MSE)。这些指标能够从不同角度评估模型在正弦波、三角波、梯形波三类波形分类任务中的表现。

- 召回率 (Recall)

召回率衡量的是模型能够识别出特定类别的样本的比例，召回率关注的是分类模型的漏检率。对于励磁波形分类，召回率衡量模型在波形分类时，有多少实际属于该类别的波形被正确识别出来，召回率越高，说明模型对励磁波形的分类效果越好。

$$\text{Recall} = \frac{TP}{TP + FN} \quad (20)$$

其中：TP 表示模型正确分类为该类别的样本数，FN 表示实际属于该类别，但被错误分类为其他类别的样本数。

- **精确率（Precision）**

精确率衡量的是模型预测某个类别时，实际属于该类别的样本的比例，精确率关注的是分类的准确性，精确率越高，说明模型对励磁波形分类的结果更准确。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (21)$$

其中，TP 表示模型正确分类为该类别的样本数，FP 表示被错误分类为该类别的样本数。

- **F1 分数（F1-score）**

F1 分数是精确率和召回率的调和平均值，当精确率和召回率存在不平衡时，F1 分数能够提供一个综合评估。较高的 F1 分数值表示该励磁波形分类在保证较低误分类的同时，也能较好地分辨实际类别。

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (22)$$

- **均方误差（MSE）**

均方误差用于衡量预测值与实际值之间的偏差，在分类问题中，常用于衡量模型输出的概率分布与真实类别标签之间的误差。均方误差越小，表示模型的预测值与真实值之间的偏差越小。对于励磁波形分类，MSE 可以衡量模型的输出概率与实际类别的接近程度，尤其在多分类问题中，能够评估模型预测的置信度是否准确。

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (23)$$

通过模型训练得到的各分类模型评估指标对比结果如表 4-1 所示。我们发现，XGBoost 分类模型在励磁波形分类问题中表现最优，其召回率和精确率均较高且相当，表明该模型在有效识别不同波形类别的同时，误分类率较低。此外，F1 分数的优异表现进一步证明了 XGBoost 在平衡精确率和召回率的同时，能够较好地区分实际的波形类别。因此，我们最终选择 XGBoost 分类模型作为本题的励磁波形分类方案。

表 4-1 机器学习励磁波形分类模型预测准确率汇总表

	RF	SVM	KNN	DT	GB	LR	NB	XGB
Precision	0.9873	0.9489	0.9499	0.9791	0.9734	0.9172	0.8747	0.9896
Recall	0.9858	0.9521	0.9440	0.9769	0.9737	0.9196	0.8785	0.9876
F1-score	0.9865	0.9503	0.9465	0.9779	0.9735	0.9183	0.8755	0.9885
MSE	0.0145	0.0508	0.0573	0.0230	0.0274	0.0827	0.1310	0.0125

4.3 分类结果展示

通过上述模型训练及模型评估的结果对比，选择分类效果最好的 XGBoost 模型作为最终的励磁波形分类模型。根据题目要求我们运用训练的 XGBoost 模型对附件二中的 80 个励磁波形进行分类，分类得到三种波形的数量统计如下表 4-2 所示。

表 4-2 附件二 80 个样本磁芯波形分类统计表

波形类型	数量
正弦波 (1)	20
三角波 (2)	44
梯形波 (3)	16

其中，特别把附件二中样本序号为：1、5、15、25、35、45、55、65、75、80 的励磁波形的分类结果展示在如下表 4-3 中。

表 4-3 问题一指定序号样本磁芯励磁波形分类结果展示表

序号	励磁波形分类结果
1	三角波 (2)
5	三角波 (2)
15	正弦波 (1)
25	三角波 (2)
35	梯形波 (3)
45	梯形波 (3)
55	三角波 (2)
65	三角波 (2)
75	三角波 (2)
80	正弦波 (1)

5 问题二：斯坦麦茨方程的修正

5.1 斯坦麦茨方程效果分析

5.1.1 斯坦麦茨方程系数拟合

根据题目介绍，斯坦麦茨方程是一种较为常见的经验计算模型，主要被用于描述正弦波励磁下磁芯元件的磁芯损耗。该方程以磁通密度、频率以及材料的物理特性为参数，描述了磁芯损耗与频率、磁通密度之间的关系。其基本计算公式如下：

$$P = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \quad (24)$$

其中， P 表示磁芯损耗； f 表示频率； B_m 表示磁通密度的峰值； k_1 、 α_1 、 β_1 是根据实验数据拟合的系数，且通常情况下 $1 < \alpha_1 < 3$ ， $2 < \beta_1 < 3$ 。

首先，我们从附件一中提取磁芯元件材料一在正弦波励磁下的频率、磁芯损耗值以及磁通密度等数据，将这些数据用于拟合材料一在正弦波励磁下的斯坦麦茨方程。方程拟合选用较常用的最小二乘法，具体步骤如下：

(1) **对数变换**：由于标准斯坦麦茨方程是一个非线性回归问题，因为方程中参数 α_1 和 β_1 是以指数的形式存在，因此需要对方程进行对数变换，将其转换为线性形式，再使用最小二乘法来拟合。对数变换后的斯坦麦茨方程为：

$$\ln(P) = \ln(k_1) + \alpha_1 \ln(f) + \beta_1 \ln(B_m) \quad (25)$$

经过对数变换后，可令 $Y = \ln(P)$ ， $X_1 = \ln(f)$ ， $X_2 = \ln(B_m)$ ， $C = \ln(k_1)$ ，则标准斯坦麦茨方程转化为线性形式 $Y = C + \alpha_1 X_1 + \beta_1 X_2$ ，可使用最小二乘法来拟合该标准的线性回归问题。

(2) **线性回归拟合**：以 Y 为目标变量， X_1 和 X_2 作为自变量，使用 Python 的 SciPy 库中 `curve_fit` 函数进行线性回归模型的拟合，求出系数 α_1 、 β_1 以及截距项 C 的值。

(3) **取指数反变换**：对截距项 C 取指数，得到初始方程系数 k_1 的值。

$$k_1 = e^C \quad (26)$$

综上所述，可求得磁芯元件材料一在正弦波励磁下的斯坦麦茨方程为（系数保留四位小数）：

$$P_1 = 1.4998 \cdot f^{1.4296} \cdot B_m^{2.4713} \quad (27)$$

同理可得，材料二、材料三、材料四在正弦波励磁下的斯坦麦茨方程分别为：

$$\begin{aligned} P_2 &= 0.5614 \cdot f^{1.5128} \cdot B_m^{2.3211} \\ P_3 &= 0.9705 \cdot f^{1.4907} \cdot B_m^{2.3854} \\ P_4 &= 0.3997 \cdot f^{1.5781} \cdot B_m^{2.4526} \end{aligned} \quad (28)$$

5.1.2 效果分析

为了了解工作温度变化对于标准斯坦麦茨方程在磁芯损耗预测中的影响，我们使用不同材料在正弦波励磁下的斯坦麦茨方程对其磁芯损耗进行预测。针对同一磁芯材料，不同温度变化下的磁芯损耗预测误差进行对比分析，探索温度变化对斯坦麦茨方程预测效果的影响。其中，选取的磁芯损耗预测误差统计指标如下：

- **均方误差 (MSE)**

均方误差是模型预测值与实际值之间差异的平方的平均值，反映了预测值偏离实际值的程度。在磁芯损耗预测中，MSE 越小，说明模型预测值与实际损耗值之间的整体误差越小。

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (P_i - \hat{P}_i)^2 \quad (29)$$

- **平均绝对误差 (MAE)**

平均绝对误差是预测值与实际值间差异的绝对值的平均值，适用于衡量损耗预测的整体偏差。

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |P_i - \hat{P}_i| \quad (30)$$

- **均方根误差 (RMSE)**

均方根误差是均方误差的平方根，和 MSE 相比，它保持了与预测量相同的单位。在磁芯损耗预测中提供了一个容易解释的误差评估指标。

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - \hat{P}_i)^2} \quad (31)$$

- **平均百分比误差 (MAPE)**

平均百分比误差^[6]衡量的是预测误差占实际值的百分比，提供了一个无量纲的误差度量指标，适合不同量级的数据进行对比。在磁芯损耗预测中，MAPE 可以有效评估模型对不同损耗值的预测误差的相对大小。

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{P_i - \hat{P}_i}{P_i} \right| \quad (32)$$

计算得到材料一、材料二、材料三和材料四分别在不同温度变化下的斯坦麦茨方程对磁芯损耗预测的误差统计结果如下表 5-1 所示。我们发现不同材料使用斯坦麦茨方程对磁芯损耗预测结果的均方误差、平均绝对误差以及均方根误差都随温度的升高而增大，说明温度的升高对斯坦麦茨方程预测结果具有直接的影响，温度越高，方程预测结果的误差越大。

与此同时，在温度为 50° C 时，四种材料使用斯坦麦茨方程对磁芯损耗预测结果的相对误差 MAPE(%) 均为最小，说明在温度为 50° C 时使用斯坦麦茨方程进行预测的误差相对值更小，即斯坦麦茨方程更适用于温度为 50° C 的磁芯损耗预测。下图 5-1 给出了材料一在不同温度下使用斯坦麦茨方程进行预测的磁芯损耗与实际磁芯损耗差异的散点图，图中直观地展示了当温度小于 50° C 时，斯坦麦茨方程预测结果相较于实际磁芯损耗更小，而当温度大于 50° C 时，斯坦麦茨方程预测结果又逐渐大于实际磁芯损耗。

表 5-1 斯坦麦茨公式在四种材料与四种温度误差汇总表

材料	温度(°C)	MSE	MAE	RMSE	MAPE (%)
材料 1	25	92455820.09	5384.8057	9615.3950	17.5474
	50	50314831.02	4010.9321	7093.2948	9.9845
	70	83415192.94	5439.3043	9133.1918	14.7845
	90	117995229.88	6994.0919	10862.5609	22.5288
材料 2	25	69026568.17	5711.6482	8308.2229	23.8241
	50	115401907.81	6578.0001	10742.5280	18.8501
	70	239901049.06	8929.1965	15488.7394	21.3195
	90	309443272.58	11318.5638	17590.9998	40.8618
材料 3	25	97397557.45	6664.9863	9869.0201	24.0833
	50	162190878.87	7129.1120	12735.4183	17.7400
	70	238467598.10	8859.1650	15442.3961	24.4919
	90	339106805.16	11989.3521	18414.8528	33.3792
材料 4	25	10393426.66	2434.4521	3223.8838	15.1640
	50	21432985.23	2890.5661	4629.5772	14.6921
	70	61670027.92	4575.8575	7853.0267	17.7597
	90	83155333.51	5735.8594	9118.9546	23.0258




图 5-1 材料一在四种温度下斯坦麦茨公式计算值与真实值散点对比图

5.2 基于温度影响的斯坦麦茨方程修正

基于上述 5.1 的分析可得，温度对斯坦麦茨方程的预测效果具有明显的影响，因此我们考虑在标准斯坦麦茨方程的基础上，加入温度（ T ）这一变量进行方程修正，使斯坦麦茨方程能够适应不同温度变化下的磁芯损耗预测。

考虑到温度（ T ）这一变量以怎样的函数形态添加到斯坦麦茨方程中，我们尝试拟合训练了如下几种常见的函数形式：

- 幂函数修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot (T^\gamma + 1)$
- 线性修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot (aT + b)$
- 二次修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot (aT^2 + bT + c)$
- 三次修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot (aT^3 + bT^2 + cT + d)$
- 指数修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot e^T$
- 对数修正： $P_{new} = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1} \cdot \log T$

对比六种函数形式修正下的斯坦麦茨方程对磁芯损耗预测的均方误差（MSE）结果如下表 5-2 所示。

表 5-2 六种潜在常用函数形式修正斯坦麦茨方程误差结果

温度修正函数形式	均方误差（MSE）	$(F(T) + 1)$ 下的均方误差（MSE）
幂函数修正	138596508.81	1159134643.71
线性修正	273567131.08	273567131.08
二次修正	134806626.04	134806625.90
三次修正	133748179.73	133748179.73
指数修正	无法拟合	无法拟合
对数修正	无法拟合	无法拟合

其中，指数和对数模型的非线性特征可能导致梯度下降法难以找到全局最优解，并且在模型复杂度较高及数据量较大的情况下，使得 SciPy 库中 `curve_fit` 方法的最大函数调用数被超出（即达到 `maxfev` 限制），最终无法实现温度变量（ T ）为指数函数和对数函数形式时，对斯坦麦茨方程修正的拟合。同时，值得一提的是在非常规 n 次函数模型修正中需要加上常数 1 以提升乘法公式的稳定性，在二次和三次修正中需要加入常数项 c 和 d 也是为了相同的目的。

最终，我们通过对比均方误差（MSE）确认温度变量（ T ）以二次函数和三次函数的形式添加到斯坦麦茨方程中对方程进行修正的效果最好。其中，二次函数在大规模计算中速度更快，当温度范围超过本题目背景下普适性（泛化能力）将会更好，三次函数可能局限于在当前数据背景下，但是预测效果较二次修正函数略微更精确。在实际运用中我们可以根据算力和精确性的需求合理选择修正模型进行使用。综合上述，给出基于温度影响的斯坦麦茨方程的修正方程为：

温度变量（ T ）以二次函数形态进行修正的模型：

$$P_{new} = -0.166320 \cdot f^{1.466724} \cdot B_m^{2.450911} \cdot (-0.000720 \cdot T^2 + 0.128109 \cdot T - 11.324206) \quad (33)$$

温度变量 (T) 以三次函数形态进行修正的模型:

$$P_{new} = 0.000009 \cdot f^{1.467336} \cdot B_m^{2.451563} \cdot F(x) \quad (34)$$

$$F(x) = (-0.080098 \cdot T^3 + 26.476972 \cdot T^2 - 2965.916855 \cdot T + 191461.534813)$$

5.3 基于温度的 N 次函数斯坦麦茨方程修正效果对比

基于附件一中材料一的正弦波励磁数据, 分别使用标准斯坦麦茨方程、基于温度变量 (T) 以二次函数形态进行修正的方程以及基于温度变量 (T) 以三次函数形态进行修正的方程进行磁芯损耗的预测, 并使用 5.1.2 中的四个误差统计指标来对比分析三者的预测效果, 结果如下表 5-3 所示。

表 5-3 标准斯坦麦茨方程及其修正方程误差评估汇总表

模型	MSE	MAE	RMSE	MAPE (%)
标准斯坦麦茨方程	1638190471.65	20615.54	40474.57	35.66
二次函数形式修正的方程	134806626.04	6775.25	11610.63	22.19
三次函数形式修正的方程	133748179.73	6716.80	11564.95	22.10

通过对比显著发现, 修正后的斯坦麦茨方程比标准斯坦麦茨方程对于磁芯损耗预测的均方误差将近缩小了 12 倍, 同时平均绝对误差、均方根误差和平均百分比误差也有极大的改善, 证明该问题中基于温度影响的斯坦麦茨方程修正模型有效。下图 5-2、图 5-3 清晰展示了标准斯坦麦茨方程、基于温度变量 (T) 以二次函数形态进行修正的方程和基于温度变量 (T) 以三次函数形态进行修正的方程对磁芯损耗的预测结果同实际磁芯损耗的对比, 更加直观地展示出修正后模型的预测效果显著提升。




图 5-2 标准斯坦麦茨方程及其修正方程损耗值预测散点对比图




图 5-3 斯坦麦茨方程及其修正方程损耗值预测 3D 折线对比图

6 问题三：磁芯损耗因素分析

6.1 因素独立作用分析

(1) 统计分析：对不同材料、励磁波形和温度的类型数量进行统计

首先进行数据预处理，对附件一中的实验数据进行清洗和整合，确保数据的完整性和有效性。数据结构包括温度、频率、磁芯损耗、励磁波形类型和磁芯材料。对表格进行合并处理，附件一中的四张子表分别对应四种不同材料的实验数据，它们具有相同的数据结构和格式，适合直接合并。

在每张子表中通过 `insert` 函数添加“材料”列，分别标记为材料 1、材料 2、材料 3、材料 4。使用 Pandas 的 `concat` 函数将四张子表合并为一个单一的数据集。




图 6-1 磁芯材料按材料波形温度分类统计条形图

通过不同材料、励磁波形和温度的类型数量可视化操作，数据中材料类别的数量分布为材料 1>材料 2>材料 3>材料 4；励磁波形类别的数量分布为三角波>正弦波>梯形波；温度类别的数量分布为 25℃>90℃>50℃>70℃。

(2) 为便于展示数据分布的密度估计，采用结合箱型图和密度图的特点的小提琴图 (violin plot) 分析不同材料、励磁波形和温度条件下的磁芯损耗分布。

不同材料的磁芯损耗分析：由小提琴图，图中四种材料（材料 1、材料 2、材料 3、材料 4）的磁芯损耗分布，观察到材料 4 的小提琴图中尖锐的峰值，集中在较低的损耗值区域，表明材料 4 在测试条件下具有较低的损耗特性和较高的一致性。相比之下，材料 2 和材料 3 的小提琴图峰值较宽，且向较高的损耗值区域偏移，意味着这些材料在相同的测试条件下性能不够稳定，呈现更敏感的状态。材料 1 的峰值最高，但是大部分集中在低损耗区，说明材料 1 的不稳定性最差，表明该材料的性能在某些条件下与其他材料相比有显著差异。

不同励磁波形的磁芯损耗分析：图 6-2 中正弦波励磁的小提琴图表现出一个明显的峰值，位于所有波形中的最低损耗值区域，与正弦波励磁通常具有较低损耗的预期相符。对于三角波和梯形波励磁，小提琴图可能显示出更宽的分布和更高的峰值，表明非正弦波励磁可能导致损耗增加，原因可能是波形的不连续性导致磁芯内部产生了更多的磁滞和涡流损耗。

不同温度下的磁芯损耗分析：随着温度的升高，所有材料的磁芯损耗普遍降低，图中小提琴图的峰值向左移动。在较高温度下，磁芯损耗的分布较为集中，表明在高温条件下磁芯的性能较为一致。随着温度的降低，分布变得更加分散，表明低温下材料的磁性质变

得更加敏感和不稳定，损耗的变异性增大，可能是由于材料的磁性质退化。




图 6-2 磁芯按材料波形温度分类小提琴图

(3) 为更直观研究三个关键自变量（材料、励磁波形、温度）与因变量（磁芯损耗）之间的关系，利用散点图来做可视化处理。




图 6-3 磁芯按材料波形温度分类散点图

图 6-3 第一张子图展示了不同材料（材料 1、材料 2、材料 3、材料 4）与磁芯损耗之

间的关系。从散点图上，可以观察到：材料 2 和材料 4 的散点集中在磁芯损耗较低的区域，表明材料 2 和材料 4 可能具有较好的磁性能，损耗较低。材料 1 和材料 3 的散点较为分散，覆盖了中等至较高的损耗区域，意味着这些材料的性能不如材料 4 稳定或者在不同条件下表现差异较大，暗示材料 1、3 在当前测试条件下可能不是最优选择。

图 6-3 第二张子图展示了不同励磁波形（正弦波、三角波、梯形波）与磁芯损耗之间的关系。从散点图上，可以观察到：正弦波励磁的散点呈现较为集中且损耗较低的分布，三角波和梯形波励磁的散点更分散，且向损耗值较高的区域偏移，表明非正弦波励磁可能导致更高的磁芯损耗。

图 6-3 第三张子图展示了不同温度（25℃>50℃>70℃>90℃）与磁芯损耗之间的关系。从散点图上，可以观察到：70℃的磁芯损耗的散点较为集中，且损耗值较低，表明在较高温条件下磁芯的损耗性能较好。随着温度的降低，损耗值会呈现更分散的状态，且损耗增加；随着温度的升高，散点向损耗值较高的区域偏移。

(4) 相关性分析

在统计分析中，相关性分析是用来评估两个或多个变量之间是否存在某种统计关联的方法。在研究磁性元件的磁芯损耗时，相关性分析可帮助我们了解不同因素（材料类型、励磁波形和温度）与磁芯损耗之间的关系。以下是进行相关性分析的步骤：

确定目标：研究材料类型、励磁波形和温度与磁芯损耗之间的相关性，并研究材料类型、励磁波形和温度自变量之间的关系。

选择相关性统计度量：常见的度量主要有皮尔逊相关系数（Pearson correlation coefficient）、斯皮尔曼等级相关系数（Spearman's rank correlation coefficient）、点双列相关系数（Point biserial correlation coefficient）。由于自变量材料类型、励磁波形和温度都为分类变量，并且从散点图可以看出变量之间可能存在非线性关系，故选用斯皮尔曼等级相关系数进行相关性分析。

为探究材料类型、励磁波形以及温度这三个关键因素对磁芯损耗的影响，采用线性回归模型和数据可视化技术进行了详尽的分析。通过构建线性回归模型，量化每个因素对磁芯损耗的具体贡献，并通过可视化手段分析。可视化结果如下图 6-4：




图 6-4 磁芯材料波形温度损耗皮尔逊相关性矩阵热力图

首先，分析各自变量与因变量的相关程度。从图中可以看出，励磁波形与磁芯损耗的相关系数比材料与磁芯损耗的相关系数和温度与磁芯损耗的相关系数都大。在此基础上，我们可以看到励磁波形与磁芯损耗成正相关关系，并且可以得到不同励磁波形的磁芯损耗从小到大排序为：正弦波<三角波<梯形波；材料与磁芯损耗和温度与磁芯损耗成负相关关系，并且可以得到不同温度的磁芯损耗从大到小排序为：25>50>70>90，不同材料的磁芯损耗从大到小排序为：材料 1>材料 2>材料 3>材料 4。

接着，分析自变量之间的影响程度。从图中可以看出，温度对励磁波形和磁芯材料的影响都非常小，说明温度因素在该系统中对励磁波形和磁芯材料的作用力较低；励磁波形对磁芯材料的影响较大，说明励磁波形是影响磁芯材料性能的关键因素，可能对磁芯材料的磁性能、损耗特性等有显著影响

(5) 岭回归

磁芯损耗是指磁性材料在交变磁场作用下产生的功率损耗，与多种因素有关，包括但不限于励磁波形、工作温度以及磁芯材料。但是这些因素之间可能存在复杂的相互作用，协同影响着磁芯损耗。岭回归（Ridge Regression）作为一种专门用于处理多重共线性问题的线性回归方法，当研究温度、材料、励磁波形对磁芯损耗的影响时，岭回归在最小二乘法的基础上，通过引入 L2 正则化项来减少各个影响因素之间多重共线性，提高模型的稳定性。岭回归的数学表达式为：

普通最小二乘法回归的目标是最小化损失函数，损失函数为：

$$\min \sum_{i=1}^n (y_i - \bar{y}_i)^2 = \min \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \quad (35)$$

其中， y_i 是实际值， $\bar{y}_i$ 是预测值， β_0 是截距， β_j 是回归系数， x_{ij} 是特征值。

岭回归在此基础上增加了一个正则化项（也称为惩罚项），定义损失函数为：

$$L(\beta_j) = \min \sum_{i=1}^n (y_i - \bar{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad (36)$$

其中， λ 是正则化参数（岭系数），用于控制惩罚项的强度。当 $\lambda = 0$ 时，岭回归退化为普通最小二乘法。当 λ 增大时，模型参数 β_j 被压缩，从而减少多重共线性和过拟合。

为找到损失函数最小时的 β_j ，对 $L(\beta_j)$ 求导，令导数为 0。

$$\frac{\partial L(\beta_j)}{\partial \beta_j} = 0 \quad (37)$$

求解方程，得到最佳的岭回归系数 β_j 。

对附件一中的数据进行最小二乘法回归，求出结果，其中，OLS 回归均方误差为 129552854862.92586，OLS 回归系数为[-27767.24356756, 71335.35733618 -11842.57903604]；再对数据进行岭回归，经过对比，发现当 $\beta_j = 500$ 时，拟合的误差较小，其中，岭回归均方误差为 129519990234.25545，与 OLS 比较，明显降低，得到的岭回归系数为[-26292.51375442, 67859.35640067 -11373.63023087]。为更直观地展示两种回归方法的效果，对两种方法的拟合曲线进行比较，发现线性模型无法充分拟合数据。图 6-5 中虚线代表了

理想情况下预测值和真实值应当完全一致的情况（即 $y = x$ 线）。如果模型的预测效果较好，点应该围绕红线对称分布。然而，图 6-5 中大多数点都远离这条线，尤其是在较大的真实值区域，说明模型对这些数据的预测存在明显误差。




图 6-5 多元线性回归模型拟合散点对照图

6.2 交互协同对磁芯损耗影响模型

6.2.1 交互项特征构造

多元统计分析中，交互作用^[7]是指一个自变量的效果在另一个自变量每一水平上表现出不一样的特性，两因素同时存在时的效应作用不等于两因素单独作用时的效应和。当温度和励磁波形同时作用于磁芯损耗时，就可能产生交互作用，即当温度和励磁波形同时存在时，所导致的磁芯损耗不等于温度和励磁波形单独效应增加时的磁芯损耗。协同作用，通常指正交互作用，即同时存在导致的效应大于单独存在的情况。不考虑交互作用时的回归模型为

$$L(T, W, M) = \beta_0 + \beta_1 T + \beta_2 W + \beta_3 M + \varepsilon \quad (38)$$

其中， $L(T, W, M)$ 为磁芯损耗， T ， W ， M 分别表示温度，励磁波形，材料， β_0 为截距项， β_1 ， β_2 ， β_3 分别是温度、材料、励磁波形的回归系数， ε 是误差项。

如果温度、励磁波形和磁芯材料两两之间存在显著的交互效应，那么简单的主效应并不能完全描述温度、励磁波形和磁芯材料对磁芯损耗的影响，也就无法正确判断磁芯损耗达到最小的条件，故需考虑自变量之间的联合效应。根据题中描述，只考虑特征两两之间的协同作用，故假设三个特征之间没有协同作用。因此，在磁芯损耗因素分析过程中，需要构建双特征交互项特征，来捕捉特征的交互效应，目前构造交互项特征的方法主要有特征乘积、多项式特征生成等。在这里，我们采用特征乘积形式构建交互项，得到的回归模型为

$$L(T, W, M) = \beta_0 + \beta_1 T + \beta_2 W + \beta_3 M + \beta_4 (T \times W) + \beta_5 (T \times M) + \beta_6 (W \times M) + \varepsilon \quad (39)$$

其中 β_4 ， β_5 ， β_6 分别表示温度和励磁波形、温度和材料、励磁波形和材料交互项的系数。

6.2.2 相关性分析

对引入的交互变量再次进行皮尔逊相关性分析，绘制相关性热力矩阵图 6-6。

• 各变量对磁芯损耗的影响分析

通过观察绘制的相关性热力矩阵，我们发现与磁芯损耗相关性较强的是励磁波形、温度与励磁波形的交互项、励磁波形与磁芯材料的交互项，每个特征项中都包含励磁波形，说明励磁波形对磁芯损耗的影响非常显著，可能是由于励磁波形的频率和幅度与磁芯损耗密切相关，在与特定的温度和材料组合的情况下，频率和幅度呈现特定的情况，磁芯表现出更大的损耗。除此之外，我们还可以发现所构建的三个交互项与磁芯损耗的相关性都较强，其中温度与励磁波形的交互项对磁芯损耗的影响最显著，进一步说明我们在分析和研究影响磁芯损耗的因素时，不能只针对单一特征对磁芯损耗的影响，还要考虑交互项对磁芯损耗的影响，因为磁芯损耗是一个复杂的物流过程，温度与励磁波形交互的过程中，温度会影响励磁波形的稳定性，反过来励磁波形的类型也会导致温度的升高或降低，从而增加或降低磁芯损耗。

• 各自变量之间的影响程度分析

在探究影响磁芯损耗的自变量各自的影响过程中，励磁波形和温度与励磁波形的交互项的相关性系数最高，说明它们之间互相影响的程度最高；温度和励磁波形与磁芯材料的交互项的相关性系数最低，说明在励磁波形与磁芯材料交互以后，温度对其影响特别小，也进一步说明温度和励磁波形与磁芯材料的交互项的交互作用不明显。




图 6-6 增加交互变量后的皮尔逊相关性热力图

另外，再次对原始变量和交互变量做线性回归分析依旧无法成功拟合磁芯损耗高值数据。图 6-7 中显示的大量散点集中在低值区，意味着岭回归模型可能在较大的磁芯损耗数据范围内失去了预测的准确性。特别是大多数散点都处于真实值大于 1×10^6 的区

域，而预测值却基本集中在较低范围内，说明岭回归可能过于平滑，未能捕捉到复杂数据的变化。这也说明磁芯损耗与温度、励磁波形以及磁芯材料不存在简单的线性关系，这也与图 6-6 相关性矩阵最后一列相吻合。




图 6-7 交互多元线性回归模型拟合散点对照图

6.2.3 随机交互森林（RIF）模型

在研究磁性元件的磁芯损耗过程中，考虑材料、励磁波形和温度之间的协同作用是必要的，因为这些因素在物理过程中往往是相互依赖和影响的，比如磁性材料的磁滞特性会随着温度的变化而变化，进而影响磁芯损耗；温度和励磁波形的变化会影响磁芯内部涡流的分布和大小，进而影响损耗；材料的磁导率会随温度变化，影响磁芯对磁场的响应等，均说明材料、励磁波形和温度之间的协同作用。在定量研究过程中，常常把协同作用造成的影响以构建交互项的形式呈现。

考虑到所给附件 1 中的材料、励磁波形和温度均为分类变量，选择随机森林构建考虑协同作用的磁芯损耗模型。由于题目要求**仅讨论温度、励磁波形和磁芯材料这三个因素两两之间协同影响**，所以在构建随机森林模型时我们仅使用三个因素及其交互变量共 6 个变量，我们发现已经有学者 Chao-Yu Guo 在 2022 年将其命名为**随机交互森林**（Random Interaction Forest, RIF）[8]。

作为一种专门用于捕捉特征交互的机器学习模型，随机交互森林基于传统的随机森林算法，进行了改进，以更有效地模拟特征之间的交互作用。核心思想是在模型的前几个决策树节点中明确地包含交互特征，强制模型在初步的学习阶段就考虑特征之间的相互作用，从而提高了对交互效应的识别能力和模型的准确性和鲁棒性，并且提供了一种在不显式定义交互项的情况下，通过树的分裂来捕捉变量之间的非线性交互效应的方法。

考虑变量交互的随机森林主要包括交互特征构建、决策树生长和投票三个环节。具体工作过程为：①构建交互项：将材料、励磁波形和温度三个特征进行两两直接相乘处理；②随机抽样：有放回地抽取样本构建决策树，并将样本点作为决策树根节点；③随机选取属性：从材料、励磁波形、温度以及构建的三个交互项六个属性中随机选取，构建节点分裂属性⑤重复抽取属性：直到不能再分裂和不能建立决策树，形成森林。

通过随机交互森林构建特征重要性指标，通过可视化分析，研究材料、励磁波形、温度以及材料、励磁波形、温度两两之间组成的交互项对磁芯损耗的影响。




图 6-8 随机交互森林特征重要性条形图

从图 6-8 中可以看出，励磁波形的特征重要性最高，对磁芯损耗的影响最为显著，可能是因为励磁波形的几何特征、频率或幅值直接调控了磁芯内部磁场的波动，从而对磁芯损耗造成了显著影响；紧随其后的是材料特征，重要性也不容忽视，说明不同材料的磁芯的物理性质和化学性质会对磁芯损耗产生重要影响，出现该情况可能是因为不同的材料具有不同的电阻率、磁导率和热导率等特性直接影响磁芯在工作过程中的能量转换和损耗。相比之下，励磁波形与磁芯材料的交互作用以及温度与励磁波形的交互作用对磁芯损耗的影响则相对较小，但这并不意味着它们的作用可以被忽略。值得注意的是，尽管温度与磁芯材料的交互项的特征重要性不及单独的磁芯材料特征，但其影响力却超过了单独的温度特征，说明该交互项对磁芯损耗具有显著性影响。综上所述，特征重要性分析揭示了影响磁芯损耗的多个关键因素及其交互作用，表明在对磁芯损耗进行分析和优化时，不能仅仅关注单一特征，而应综合考量所有相关特征及其潜在的相互作用。通过这种方式，可以更全面地理解和分析影响磁芯损耗的因素，为磁性元件的设计和性能提升提供有力的数据支持。

6.3 最小磁芯损耗的因素选择模型

根据题目描述，磁芯损耗作为磁性元件性能的关键指标，直接影响到设备的能量转换效率和长期运行的可靠性。在设计和优化磁性元件的过程中，理解和控制磁芯损耗变得尤为关键。磁芯损耗主要由三部分组成：磁滞损耗、涡流损耗和附加损耗，其在磁性元件工作时不可避免，但通过精心设计可以最小化。在众多影响磁芯损耗的因素中，温度、励磁波形以及磁芯材料是公认的三大核心要素。温度影响材料的磁性能，励磁波形决定了磁通密度的变化速率，而磁芯材料本身的属性则是决定损耗大小的基础。而温度、励磁波形和磁芯材料相互之间对磁芯损耗又有协同影响。该模型需要以最小磁芯损耗为目标，构建单目标优化模型，并求解磁芯损耗达到最小时的可能的温度、励磁波形和磁芯材料的组合条件。

目标函数表达式为：

$$\min L(T,W,M) \tag{40}$$

约束条件为:

$$\begin{cases} T \in \{25, 50, 70, 90\} \\ W \in \{\text{正弦波, 三角波, 梯形波}\} \\ M \in \{\text{材料 1, 材料 2, 材料 3, 材料 4}\} \end{cases} \tag{41}$$

其中 $L(T,W,M)$ 表示磁芯损耗函数, T 表示温度, W 表示励磁波形、 M 表示材料类型。

(1) 排序法

在温度仅考虑 4 种类型的情况下，我们发现约束条件的总组合数有限，于是可以通过不同条件组合下的磁芯损耗均值（从小到大排序）分析得到磁芯损耗最小的结果：

表 6-1 按照温度波形材料分类均值顺序排序表（前五）

温度	励磁波形	磁芯材料	磁芯损耗
90	正弦波	4	37860.126541
70	正弦波	4	40432.670824
50	正弦波	4	46663.650828
25	正弦波	4	48728.833809
70	正弦波	3	74524.828080

(2) 两两对比法

或者我们也可以通过可视化两两因素组合热力图观察得到：




图 6-9 两因素组合磁芯损耗均值热力图

图 6-9 第一个子图不同温度和励磁波形组合下的磁芯损耗均值的热力矩阵图中，可以观察到不同组合下的磁芯损耗均值，当温度为 70℃ 且励磁波形为正弦波时，磁芯损耗均值最小，说明在该组合下磁芯的性能得到了最佳的发挥，说明在正弦波下，保持 70℃ 的温度条件，能够使磁芯在能量转换过程中更加高效、稳定，从而降低损耗、提高设备性能，为磁芯材料的研发以及控制磁芯工作环境提供了具有实际意义的指导。相对地，当励磁波形为梯形波且温度为 25℃ 时，磁芯损耗均值最大，说明该条件下不适合磁芯的使用，会造成磁芯内部更多的能量消耗，从而增加磁芯的损耗。

图 6-9 第二个子图不同磁芯材料和温度组合下的磁芯损耗均值的热力矩阵中，可以观察到不同组合下的磁芯损耗均值，当温度为 90℃ 且磁芯材料为材料 4 时，磁芯损耗均值最小，说明在该组合下，磁芯的磁性能得到了最佳的发挥，能够有效地降低磁芯的损耗，对于实际应用中磁芯材料的选择和温度控制具有重要指导作用，尤其是对于电力电子系统、

变压器、电感器等设备的设计至关重要，因为它们都依赖于高效的磁芯性能来减少能量损失、提高效率和稳定性。相对地，当温度为 25°C 且磁芯材料为材料 3 时，磁芯损耗均值最大，说明材料 3 在常温（如 25°C）下可能具有相对较高的电阻率或磁滞损耗，导致其在该温度下的整体损耗较大，并且这种温度影响材料 3 上表现得最为明显。

图 6-9 第三个子图不同磁芯材料和励磁波形组合下的磁芯损耗均值的热力矩阵图中，可以观察到不同组合下的磁芯损耗均值，当励磁波形为正弦波且磁芯材料为材料 4 时，磁芯损耗均值最小，说明在该组合下磁芯的性能得到了最佳的发挥，正弦波作为一种平滑、连续的波形，在励磁过程中能够减少磁芯内部的应力突变和能量损耗，而且材料 4 对正弦波励磁具有良好的适应性，对于次新设计与制造具有指导建议。相对地，当励磁波形为梯形波且磁芯材料为材料 3 时，磁芯损耗均值最大，说明材料 3 的磁芯在梯形波中受到更多的内部应力突变和能量损耗。

通过上述分析，我们可以得到，当达到最优磁芯损耗时，温度、磁芯材料、励磁波形的可能组合为 90°C、材料 4、正弦波。

7 问题四：基于数据驱动的磁芯损耗预测模型

7.1 XGBoost 回归预测模型

基于数据相关性复杂且维度较高的特点和问题对特征可解释性的需求，选择了 XGBoost 回归模型，兼顾了预测精度和模型解释性。

XGBoost 算法通过集成学习的方式，能将多棵决策树组合起来，从多个特征中学习并预测磁芯在特定条件下的损耗，相比于其他算法，一定程度上提高了预测的准确性和鲁棒性。XGBoost 通过集成多棵决策树的方式，每棵树都尝试纠正前一棵树的预测误差。对于磁芯损耗预测模型，我们可以捕捉到由多个因素（如温度、频率、磁通密度等）组合影响的复杂模式。

- **预测模型构建：**

在磁芯损耗预测任务中，XGBoost 通过构建一系列决策树来累加预测结果。对于每个样本 i ，其预测值 $\bar{y}_i$ 是由 K 棵树的预测结果之和构成的：

$$\bar{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (42)$$

其中 x_i 表示样本的特征向量， $f_k(x_i)$ 表示第 k 棵树对样本 x_i 的预测结果

- **目标函数优化：**

XGBoost 最小化一个包含正则化项的目标函数，防止模型在训练数据上过拟合，从而提高模型在未知数据上的泛化能力，提高磁芯损耗模型在不同操作条件下的预测精度。目标函数定义为：

$$obj = \sum_{i=1}^n L(y_i, \bar{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (43)$$

其中， $L(y_i, \bar{y}_i)$ 为损失函数，用于衡量真实值 y_i 和预测值 $\bar{y}_i$ 之间的差距。通常采用均方误差 $L(y_i, \bar{y}_i) = \frac{1}{2}(y_i - \bar{y}_i)^2$ 。 $\Omega(f_k)$ 是正则化项，控制决策树的复杂度，常见形式为： $\Omega(f_k) =$

$\partial T + \frac{1}{2}\lambda \sum w_j^2$ ，其中 T 为树的叶节点数， w_j 为叶子节点的权重， ∂ 和 λ 是超参数。

- **模型更新：**

XGBoost 通过逐步添加新的决策树来更新模型，每一步都针对前一步的残差进行优化，通过一系列的弱学习器（决策树）累加得到预测值 $\bar{y}_i$ ：

$$\bar{y}_i^{(t)} = \bar{y}_i^{(t-1)} + f_t(x_i) \quad (44)$$

允许模型逐渐学习磁芯损耗数据中的温度、材料等因素之间的复杂关系，并在每一步中改进预测。

- **二阶泰勒展开：**

为优化目标函数和更好地处理磁芯损耗预测中的非线性关系，XGBoost 使用二阶泰勒展开近似损失函数：

$$L(y_i, \bar{y}_i^{(t)}) \approx L(y_i, \bar{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \quad (45)$$

其中， $g_i = \frac{\partial L(y_i, \bar{y}_i^{(t-1)})}{\partial \bar{y}_i^{(t-1)}}$ 是损失函数对预测值的一阶导数（梯度）， $h_i = \frac{\partial^2 L(y_i, \bar{y}_i^{(t-1)})}{\partial \bar{y}_i^{(t-1)^2}}$ 是

损失函数的二阶导数（Hessian）。

• 叶子节点的分裂与权重优化：

在构建决策树的过程中，XGBoost 通过计算增益来决定是否进行节点分裂，以及如何确定叶子节点的权重：

$$w_j^* = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (46)$$

其中， I_j 是叶子节点 j 包含的样本集合。

而分裂节点的增益（Gain）是：

$$\text{Gain} = \frac{1}{2} \left(\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right) - \theta \quad (47)$$

增益决定了分裂是否值得，若增益较大则进行分裂。

通过上述步骤，XGBoost 能有效地预测磁芯损耗，有助于元件使用者和设计者在设计磁性元件时考虑到各种工况条件下的损耗特性，从而优化磁性元件的性能。

在代码层面，建立 XGBoost 模型借助了问题一模型特征选择及数据预处理加工后数据表格，其中最重要的数据预处理操作是主成分分析（PCA 降维），这是能够成功建立 XGBoost 回归预测模型的点睛之笔。




图 7-1 由最终 XGBoost 回归模型导出的树模型一角

7.2 模型效果分析

7.2.1 预测精度分析

在 7.1 中，我们基于附件一中的数据建立了 XGBoost 磁芯损耗预测模型。为了更深入分析模型的预测精度，我们将 XGBoost 模型与传统的基于物理学的斯坦麦茨方程及其修正方程，以及其他机器学习和深度学习模型进行了误差对比分析。

（1）XGBoost 模型预测结果误差

从图示的 XGBoost 模型预测值与真实值的散点分布可以初步判断出，该模型具有较高的预测精度。在此基础上，通过对数据集进行训练集和测试集的拆分，以及使用 5 折交叉验证方法，进一步分析了模型的综合误差。




图 7-2 XGBoost 模型磁芯损耗预测真值散点对照图

下表列出了 XGBoost 模型在训练集和测试集上的均方误差（MSE）、平均绝对误差（MAE）、均方根误差（RMSE）以及平均百分比误差（MAPE）。根据误差结果，XGBoost 模型在测试集上的综合表现优异，误差幅度在训练集和测试集之间保持稳定，体现了模型的强泛化能力。

表 7-1 XGBoost 模型磁芯损耗预测结果误差表

XGBoost	MSE	MAE	RMSE	MAPE (%)
训练集	175387188.4	8017.463383	13243.38282	22.13267769
测试集	89998919.19	5874.405569	9486.776017	25.23193332
误差幅度对比	0.513144	0.732701	0.716341	1.140031
交叉验证平均值	2048048505	19776.82696	45102.37324	27.02011086

从表 7-1 中可以看出，XGBoost 模型在测试集上的 MSE、MAE、RMSE 以及 MAPE 指标相对于训练集的误差幅度较小，说明模型在处理复杂非线性数据时表现出了极高的预测能力。

进一步计算了模型的误差结果与物理公式模型和其他机器学习或深度学习模型进行对比得到如下表格。

（2）与其他模型的误差对比

进一步计算了其他模型的误差结果，如基于物理公式的斯坦麦茨方程及其修正方程，支持向量回归（SVR）、多层感知器（MLP）、CatBoost、LightGBM 等机器学习或深度学习模型进行了对比。对比结果如表 7-2 其他模型模型磁芯损耗预测结果误差汇总表所示：

表 7-2 其他模型模型磁芯损耗预测结果误差汇总表

模型	MSE	MAE	RMSE	MAPE (%)
SVR	15604137242	70071.64851	124916.5211	616.9574075
MLP	7746451456	41351.16406	88013.92999	159.5760646
CatBoost	106498380.6	5814.272544	10319.80526	34.95554639
LightGBM	534582448.4	13670.33	23121.04	53.33108
原始方程	1638190472	20615.53947	40474.56574	35.66265359
二次修正方程	134806626	6775.254043	11610.62557	22.18627753
三次修正方程	133748179.7	6716.800766	11564.95481	22.10231102

在与其他模型的对比中,XGBoost 模型的误差明显低于其他传统模型和机器学习模型。尤其是在 MSE 和 RMSE 指标上,XGBoost 模型的性能显著优于支持向量回归 (SVR) 和多层感知器 (MLP) 等机器学习模型。此外,XGBoost 模型的 MAPE 值也远低于 SVR 和 MLP,证明了其在准确预测磁芯损耗上的卓越表现。

对比斯坦麦茨方程及其修正方程,XGBoost 模型在大多数误差指标上均表现出更高的精度,特别是相对于传统物理公式预测系数对磁芯材料和励磁波形的绑定,XGBoost 具有更高的预测能力和泛化能力。

7.2.2 泛化能力分析

为了确保 XGBoost 模型的泛化能力,模型训练过程中使用了数据集的合理划分方法。具体而言,数据集被划分为训练集和测试集,训练集用于模型的训练和优化,测试集作为独立数据集,用于最终的泛化能力评估。通过保持训练集和测试集的独立性,保证了模型在未见数据上的预测能力,避免了过拟合现象的发生。

为了进一步提升模型评估的精度和鲁棒性,采用了 5 折交叉验证的策略。在此过程中,将数据集随机分为 5 份,每次使用其中的 4 份作为训练数据,第 5 份作为验证数据。通过 5 次重复训练并计算验证误差,获得了更加稳定的模型评估结果。上述表 7-1 XGBoost 模型磁芯损耗预测结果误差表交叉验证的结果显示,XGBoost 模型在多次验证中的均方误差 (MSE) 和均方根误差 (RMSE) 表现非常一致,进一步证明了该模型的泛化能力。

综合上述分析,XGBoost 模型在磁芯损耗预测任务中表现出极强的泛化能力,无论是在训练集、测试集还是交叉验证中的表现都非常稳定。与传统物理模型和其他机器学习模型相比,XGBoost 模型在所有误差指标上均具有明显优势。通过对模型泛化能力的精细评估,我们可以确认 XGBoost 模型在处理复杂非线性数据方面的卓越表现,是该问题中最优的解决方案之一。

7.3 求解结果

为提升模型调用和结果处理的效率,编写了多个辅助脚本,包括 XGB 模型保存器.py、XGB 模型预测器.py、写入附件四.py 和自动提取序号表格.py,这些脚本显著加快了求解和结果处理的速度,确保了大规模样本的快速预测和结果导出。

由于 XGBoost 模型在某些情况下可能输出负值,但由于修改其他损失函数无法达成优质拟合,而负值显然不符合磁芯损耗的物理意义,因此对负值预测的处理成为关键问题。在保持模型拟合精度的前提下,经过多种策略实验对比,最终采用了最小算术平均值来替代负值。这一方法比中位数或几何平均值更为有效,且在实验中显著降低了预测误差,优

化了整体预测效果。

$$y_{\text{pred}} = \begin{cases} y_{\text{pred}} & y_{\text{pred}} \geq 0 \\ y_{\text{minimal_mean}} & y_{\text{pred}} < 0 \end{cases} \quad (48)$$

其中 y_{pred} 是预测值， $y_{\text{minimal_mean}}$ 是负值出现数量的磁芯损耗最小实际值列表的算术平均值。

根据附件三中的要求，针对特定样本序号（16、76、98、126、168、230、271、338、348、379）的磁芯损耗预测结果如下表 7-3 所示：

表 7-3 问题四指定序号样本磁芯损耗预测结果展示表

序号	磁芯消耗预测结果
16	1129
76	157295
98	7860
126	2816
168	95127
230	75346
271	1915837
338	7099
348	796585
379	4289

7.4 业界指导建议

在磁芯损耗研究与应用领域，随着电力电子技术的迅猛进步，对磁芯材料性能的要求不断攀升，特别是在高频、大功率的复杂工作环境中，如何精确预测与控制磁芯损耗成为了亟待解决的关键技术难题。XGBoost 算法，凭借其高效的处理速度和卓越的预测精度，在构建磁芯损耗预测模型方面展现出了非凡的潜力和价值。以下是构建的磁芯损耗预测模型在业界的实际应用和指导建议。

（1）特征重要性分析：优化设计流程的指导

特征重要性分析在优化设计流程中扮演着至关重要的角色，帮助设计者识别哪些特征对模型或系统的性能、效率、准确性等方面具有显著影响。通过对模型的特征重要性进行还原分析，我们可以得出对磁芯损耗影响最大的几个特征。

需要注意的是 PCA 降维会导致信息丢失，我们并不能直接获得原始输入的特征重要性，因为参与模型训练的数据是主成分分析之后的主成分元素。PCA 的过程中会生成一个载荷矩阵（loading matrix），它表示每个主成分与原始特征之间的线性关系。我们可以通过这个矩阵分析每个主成分对哪些原始特征的解释能力强。通过获取获取 PCA 主成分的载荷矩阵可以分析每个主成分与原始特征之间的相关性，从而解释主成分的重要性。

具体的特征重要性排序如下表 7-4：

表 7-4 Xgboost 特征重要性还原表

特征名称	重要性
频率	0.493
skewness（偏度）	0.207
top_10_energy	0.171
total_energy（总能量）	0.171
min_value	0.146
peak_to_peak（幅值）	0.146
max_value	0.145
kurtosis（峰度）	0.142

• 频率对损耗的显著影响

通过特征重要性分析可以看出，频率（0.493）对磁芯损耗的影响最为显著，表明设计过程中选择合适的频率是控制磁芯损耗的关键。频率的变化直接影响电磁性能，尤其是在高频应用中，频率越高，损耗往往越大。

指导意义：在设计高频电力变换器时，控制频率成为优化损耗的重要手段。设计人员应根据具体应用场景和性能要求，合理选择工作频率。在可能的情况下，适当降低工作频率以减少损耗。针对高频应用，应选择具有低损耗特性的磁芯材料。由于高频下磁芯损耗增加，会产生更多的热量。因此，在设计中需要充分考虑散热问题，采用有效的散热措施来确保磁芯和整个电力变换器的稳定运行。

• 能量分布和波形特征的重要性

特征如 top_10_energy（前 10 个频率成分的能量）和 total_energy（总能量）对损耗的影响也较大。反映了磁芯的工作状态，以及不同频率成分如何在损耗中发挥作用。同时，skewness（偏度）和 kurtosis（峰度）等反映波形形状的特征，也对损耗产生了重要影响。

指导意义：通过调整频谱能量分布和波形形状，设计人员可以在设计中优化电路参数，减少电磁波形的非对称性和过高的能量成分，从而降低损耗。

• 磁通密度的影响

在电力变换器和磁性元件的设计中，磁通密度的变化幅度是一个至关重要的参数。特征如 min_value（最小值）、max_value（最大值）和 peak_to_peak（幅值）反映了磁通密度的变化幅度，对损耗同样有重要影响。过高的磁通密度可能导致磁芯的饱和，进而增加损耗。

指导意义：在设计中，通过限制磁通密度的变化幅度，可以减少磁芯的饱和现象，进而降低损耗。设计团队可以根据模型建议，合理设定磁芯的磁通密度范围，有助于保持较高的能量转换效率。

• 行动建议

设定合理的磁通密度目标范围，确保磁芯在正常工作条件下既不会过度饱和，又能充分利用磁场能量；考虑不同工况下的磁通密度变化，设定动态调整策略以适应不同的负载和环境条件。评估并选用具有高磁导率、低损耗特性的磁芯材料，并优化磁芯的几何结构。针对磁通密度峰值进行合理控制，避免磁芯饱和，并通过调整波形特征来优化设计。




图 7-3 XGBoost 回归预测模型特征重要性

(2) 模型的广泛适用性：跨材料和工况条件的预测

通过 XGBoost 模型对不同材料、不同工况条件下的磁芯损耗进行建模，可以提供高度泛化的损耗预测能力。以下是模型的几个关键应用领域：

• 跨材料的适应性

由于模型能够处理不同磁芯材料（如磁芯材料 1、磁芯材料 2、磁芯材料 3、磁芯材料 4）之间的特性差异，企业可以通过该模型快速评估不同材料的性能。

指导意义：在新材料的开发阶段，企业可以通过模拟快速筛选最优材料组合，避免大量实验测试的高昂成本和时间投入。

• 跨工况条件的适应性

模型不仅能够适应不同材料，还能够应对不同温度（如 25° C、50° C 等）和波形类型（如正弦波、梯形波）的变化，意味着在不同环境条件和工况下，模型都能够提供稳定的损耗预测结果。

指导意义：通过模型的广泛适用性，设计人员可以在实际工作条件下模拟损耗，提前发现设计中可能存在的风险，并进行相应调整。

• 行动建议

在不同温度、波形类型等工况条件下，使用模型进行损耗预测。设计人员可根据模型预测结果，提前发现设计中可能存在的风险，并进行相应调整。结合实际工况数据，不断优化模型，提高其在复杂条件下的预测精度。通过预测结果，技术人员应指导生产部门材料选择与工艺优化，实时监控实际损耗数据与模型预测值的偏差。研发团队应不断探索新的建模技术和方法，提高模型的预测能力和泛化能力。

(3) 模型的可解释性：为设计提供透明的决策支持

XGBoost 模型不仅提供高精度的损耗预测，还通过特征重要性分析使设计人员清楚地理解每个特征对损耗的贡献，使得模型在工业应用中不仅能够提供预测结果，还能帮助工程师理解和优化设计。

• 行动建议

在设计过程中，结合模型的可解释性，及时根据特征重要性调整设计参数，确保产品在性能和损耗之间实现最优平衡。

(4) 行业的实际应用：推动电力电子产品设计的进步

• 提升电力电子产品的能效

在设计开关电源、逆变器、变压器等应用中，精确的损耗预测能帮助企业提高产品的能效，降低发热量，延长产品寿命，从而在市场中占据竞争优势。

• 加速材料筛选与设计迭代

通过模型快速筛选不同工况下的磁芯材料表现，企业能够在更短的时间内找到最合适的材料和设计方案，从而加快研发进度，缩短上市时间。

- **行动建议**

应用数据驱动的磁芯损耗预测模型优化功率变换器的设计，减少高频工况下的损耗，并提升系统效率。利用模型缩短设计迭代时间，提高新材料的研发效率，增强市场竞争力。

8 问题五：磁性元件的最优化条件

8.1 最优化模型建立

8.1.1 确定变量和取值范围

本问题中要求建立一个实现磁性元件整体性能最优化的模型，即使磁芯损耗最小化的同时拥有最大的传输磁能，其中的优化变量包括温度 T 、频率 f 、波形 W 、磁通密度峰值 B_m 、磁芯材料 M 。

- **连续变量**

温度 T ：在实验数据中的最小值和最大值之间。

频率 f ：在实验数据中的最小值和最大值之间。

磁通密度峰值 B_m ：在实验数据中的最小值和最大值之间。

- **离散变量**

波形 W ：包括正弦波、三角波、梯形波，分别编码为 1,2,3。

磁芯材料 M ：包括材料 1~材料 4，分别编码为 1,2,3,4。

8.1.2 构建目标函数

该问题中，我们需要同时最小化磁芯损耗和最大化传输磁能，这是一个典型的多目标优化问题。因此，需要建立一个综合的目标函数，将磁芯损耗和传输磁能结合起来。

- **方法一：加权和法**

构建一个综合目标函数 F ，将磁芯损耗和传输磁能以一定的权重组合：

$$F = w_1 \cdot \frac{P}{P_{\max}} - w_2 \cdot \frac{E}{E_{\max}} \quad (49)$$

其中， w_1 和 w_2 为权重系数，满足 $w_1 + w_2 = 1$ ， $P_{\max}$ 和 $E_{\max}$ 为磁芯损耗和传输磁能的最大值，用于归一化。

- **方法二：目标比值法**

将传输磁能与磁芯损耗的比值作为优化目标：

$$F = \frac{E}{P} \quad (50)$$

其中，要求分子传输磁能 E 最大化，分子磁芯损耗 P 最小化，即分式 $\frac{E}{P}$ 值最大化。

本题中为了同时考虑最小化磁芯损耗和最大化传输磁能，我们选择方法二，将复杂的多目标优化问题转化为单目标优化问题，则目标函数如下所示：

$$\max \frac{f \times B_m}{P} \quad (51)$$

8.1.3 定义约束条件

$$s. t. \begin{cases} T_{min} \leq T \leq T_{max} \\ f_{min} \leq f \leq f_{max} \\ B_{m,min} \leq B_m \leq B_{m,max} \\ W \in \{1,2,3\} \\ M \in \{1,2,3,4\} \end{cases} \quad (52)$$

约束条件（1）表示温度的值需要在所给实验数据中的最小值和最大值之间；约束条件（2）表示频率的值需要在所给实验数据中的最小值和最大值之间；约束条件（3）表示磁通密度峰值需要在所给实验数据中的最小值和最大值之间；约束条件（4）表示离散变量波形 W 的取值范围为 $\{1,2,3\}$ ；约束条件（5）表示离散变量磁芯材料 M 的取值范围为 $\{1,2,3,4\}$ 。

8.2 遗传算法求解

接下来，我们使用遗传算法对最优化问题进行求解，遗传算法主要包括初染色体编码、初始化种群、适应度函数计算、选择、交叉、变异等基本操作。

（1）染色体编码

决策变量包括温度 T 、频率 f 、磁通密度峰值 B_m 、波形 W 和磁芯材料 M ，它们的取值范围已根据实验数据给定。在遗传算法中，一个染色体表示一个解，包含所有决策变量的取值，染色体编码可以采用实数编码和离散编码的混合方式。因此，本问题中的染色体编码可以表示为一个长度为 5 的向量，依次对应每个决策变量 T 、 f 、 B_m 、 W 、 M 的取值。

$$\mathbf{x} = (T, f, B_m, W, M) \quad (53)$$

（2）初始化种群

设定种群的大小为 N ，即每一代的种群中包含 N 条染色体。种群大小通常根据问题规模设定，一般取值在几十到几百之间。本最优化问题中 N 取 100 进行初始化种群的生成，种群中的每条染色体分别在对应变量的取值范围内随机生成各个决策变量的初始值。

$$P(0) = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\} \quad (54)$$

（3）计算适应度函数

在使用遗传算法求解磁芯损耗优化问题时，适应度函数是评估每个个体优劣的关键指标。通过适应度函数的计算，算法能够判断哪些个体具有较好的解，并优先选择这些个体进入下一代，因此，适应度函数的设计直接影响遗传算法的优化效果。本问题中，适应度函数基于目标函数为：

$$Z = \frac{f \times B_m}{P} \quad (55)$$

其中， f 为染色体的一个决策变量频率； B_m 为染色体的一个决策变量磁通密度峰值； P 是通过问题四所建立的 XGBoost 回归模型预测得到的磁芯损耗，依赖于温度 T 、频率 f 、磁通密度峰值 B_m 、波形 W 和磁芯材料 M 。

（4）选择

选择操作根据染色体的适应度值，选择一部分适应度高的染色体作为父代，以繁殖出下一代个体。常用的选择方法包括轮盘赌选择和锦标赛选择。本问题中使用轮盘赌策略进行父代选择，轮盘赌公式为：

$$p_i = \frac{Z_i}{Z_{total}} \quad (56)$$

该公式表示染色体 i 被选中作为父代的概率为染色体 i 的适应度值除以整体的适应度值。适应度越高，代表该染色体上的决策变量值越好，更容易被选中。

(5) 交叉与变异

交叉和变异是遗传算法中增加个体多样性的主要方法，其中，交叉操作通过两个父代染色体交换基因信息，生成新的子代染色体，对于连续变量（温度 T 、频率 f 、磁通密度峰值 B_m ），我们采用均匀交叉策略；对于离散变量（波形 W 和磁芯材料 M ），我们采用单点交叉（Single-point Crossover）策略。变异操作是指随机改变个体的部分基因值，以增强种群的多样性，避免算法陷入局部最优，对于连续变量（温度 T 、频率 f 、磁通密度峰值 B_m ）采用高斯噪声变异，即在某些基因位点加入小幅度的高斯噪声进行变异；对于离散变量（波形 W 和磁芯材料 M ），我们采用随机选择变异，通过随机将某个基因位点赋值为不同的类别来实现多样化。遗传算法求解的具体流程如下：

Algorithm 2 基于遗传算法求解最优化问题

- 1: **输入：**待优化的参数空间 $\mathbf{x} = \{T, f, B_m, W, M\}$ ，适应度函数 $Z = \frac{f \times B_m}{P}$ ，种群大小 N ，交叉概率 p_c ，变异概率 p_m ，最大迭代次数 G 。
 - 2: **输出：**最优参数组合 $\mathbf{x}^* = (T^*, f^*, B_m^*, W^*, M^*)$ 。
 - 3: **步骤：**
 - 4: **初始化种群：**
 - 5: 随机生成大小为 N 的种群 $P(0)$ ，每个个体为参数组合 $\mathbf{x}_i = (T_i, f_i, B_{m,i}, W_i, M_i)$ 。
 - 6: 设定初始代数 $g = 0$ 。
 - 7: **适应度评估：**
 - 8: 计算适应度函数 $Z_i = \frac{f_i \cdot B_{m,i}}{P(f_i, B_{m,i}, W_i, T_i, M_i)}$ 。
 - 9: **选择操作：**
 - 10: 根据个体的适应度值 Z_i ，采用轮盘赌选择或锦标赛选择算法选择 N 个父代个体。
 - 11: **交叉操作：**
 - 12: 执行均匀交叉（连续变量）和单点交叉（离散变量）。
 - 13: **交叉操作：**
 - 14: 执行高斯噪声变异（连续变量）和随机选择变异（离散变量）。
 - 15: **更新种群：**
 - 16: 将新的后代个体加入种群中，形成新种群 $P(g + 1)$ 。
 - 17: **迭代：**
 - 18: 设 $g = g + 1$ ，重复执行步骤 7-16，直到达到最大迭代次数 G 或适应度收敛。
 - 19: **输出最优解：**
 - 20: 选取种群中适应度值最高的个体 $\mathbf{x}^*$ ，即为最优解；输出最优参数组合 $\mathbf{x}^* = (T^*, f^*, B_m^*, W^*, M^*)$ 。
-

通过遗传算法求解得出：温度条件为 81.86℃，频率为 61737.12 Hz，磁通密度峰值为 0.3041 T，波形为正弦波，磁芯材料为材料 1 时，达到最小的磁芯损耗 $P = 28.3151 \text{ W/m}^3$ ，以及最大的传输磁能 18776.6684 J，此时，能够实现磁性元件整体性能的最优化。

9 模型评价与改进

9.1 算法有效性与复杂性分析

XGBoost 模型是一种基于梯度提升框架的高效集成学习模型，因其运行速度快、性能优异而广泛应用于回归和分类任务。其核心优势在于通过对损失函数的二阶导数进行近似来优化树结构，使得每棵树的构建更精确，提升了模型的收敛速度。与传统的梯度提升决策树（GBDT）相比，XGBoost 进一步引入了并行计算、树结构的正则化处理以及自动化特征筛选等优化策略，使得算法具备了更高的运行效率和泛化能力。

在复杂性方面，XGBoost 的时间复杂度为 $O(K \cdot n \cdot \log n)$ ，其中 K 为树的数量， n 为样本数量，且其使用了分层构建树结构的方式，使得大规模数据的训练速度显著提升。然而，随着决策树数量的增加，模型的计算开销也会相应增加。因此，在实际应用中需要合理选择树的数量、深度等超参数，在保证模型精度的同时控制复杂度。尽管 XGBoost 在性能和速度上表现优异，但其复杂性仍然取决于数据规模和模型参数，需要在不同任务场景下进行精细调整。

此外，XGBoost 模型具备较强的处理高维稀疏数据的能力，并能通过内置的正则化机制防止过拟合，使其在大多数实际应用中展现出较高的稳健性和准确性。

9.2 模型稳定性与灵敏度分析

在模型的稳定性和灵敏度方面，探讨基于不同算法的性能表现。

首先，基于二次和三次函数修正的斯坦麦茨方程在磁芯损耗预测中表现出良好的稳定性。通过对温度和频率等影响因素的函数修正，该方程有效减少了预测误差，且修正后的方程在不同工况下均展现出较高的鲁棒性。由于二次和三次修正函数的引入，方程能够较好地适应复杂非线性关系，使预测结果更加可靠。

其次，XGBoost 模型在分类和回归任务中的稳定性表现优异。XGBoost 通过树结构的优化和内置的正则化机制，显著降低了模型的随机性和过拟合风险。在多次实验中，XGBoost 模型的输出结果波动较小，且在不同数据集和任务环境下都能够保持一致的性能。通过 5 折交叉验证进一步验证了其在不同数据分割情况下的表现一致性，证明了模型的强稳健性。

此外，采用遗传算法求解 XGBoost 模型的目标函数时，速度较快且解的稳定性较高。遗传算法通过优化超参数和搜索全局最优解，有效提高了模型的求解效率。即使面对复杂的多目标优化问题，遗传算法依然能够快速收敛，并为 XGBoost 模型提供可靠的优化支持。这种结合方法不仅提升了求解速度，也增强了整体模型的稳健性和可靠性。

总体而言，基于斯坦麦茨方程的修正模型和 XGBoost 回归与分类模型在不同任务中的表现都具备较高的稳定性，同时，灵敏度分析显示它们对输入数据的波动响应较小，能够稳定输出高精度的预测结果。

9.3 优点分析

(1) PCA 是本文模型的点睛之笔，PCA 降维有效地降低了特征维度，去除了冗余信息，保留了主要特征，减少了模型的复杂度，防止了过拟合。在 XGBoost、SVR 和神经网络模型中加入 PCA 后，性能指标都有明显的提升，模型的泛化能力增强。

(2) 使用了在励磁波形分类预测和磁芯损耗回归预测使用了相同的 XGBoost 底层模

型，免于采用不同的数据特征提取方法和数据预处理方法，全文可共用一套底层特征提取数据，复用性强。

9.4 缺点分析

XGB 模型会输出负值预测的问题，但是调整损失方法拟合效果会大打折扣，所以只能对负值取最小算术平均值。

9.5 模型改进

（1）调整 PCA 参数：尝试不同的 `n_components` 值，保留更多或更少的方差，观察对模型性能的影响。

（2）特征工程：在降维前进行特征选择，去除明显无关或噪声较大的特征，进一步提高模型性能。

（3）超参数调优：继续细化超参数的搜索范围，使用贝叶斯优化等高级调优方法。

（4）数据增广：如果可能，获取更多的数据，增加模型的训练样本，提高模型的稳定性。

参考文献

- [1] 范龔. 高频逆变器功率磁芯损耗建模研究[D]. 南京邮电大学, 2023.
- [2] Bertotti G. General properties of power losses in soft ferromagnetic materials[J]. IEEE Transactions on Magnetics, 1988, 24(1): 621-630.
- [3] Rudy S. HF core loss for non-sinsoidal waveforms. Proc[J]. HFPC'91, 1991, 140-148.
- [4] Venkatachalam K, Sullivan C R, Abdallah T, 等. Accurate prediction of ferrite core loss with nonsinusoidal waveforms using only Steinmetz parameters[C]//2002 IEEE Workshop on Computers in Power Electronics, 2002. Proceedings. 2002: 36-41.
- [5] Lever J, Krzywinski M, Altman N. Principal component analysis[J]. Nature Methods, 2017, 14(7): 641-642.
- [6] de Myttenaere A, Golden B, Le Grand B, 等. Mean Absolute Percentage Error for regression models[J]. Neurocomputing, 2016, 192: 38-48.
- [7] 聂志强, 欧艳秋, 庄建, 等. 实现 logistic 与 Cox 回归相乘相加交互作用的临床实践宏程序[J]. 中华流行病学杂志, 2016, 37(5): 737-740.
- [8] Guo C Y, Lin Y J. Random Interaction Forest (RIF)—A Novel Machine Learning Strategy Accounting for Feature Interaction[J]. IEEE Access, 2023, 11: 1806-1813.

附录

表 1: 材料四合一的新特征表格.xlsx 表头特征变量解释

英文表头	中文解释
温度, oC	温度, 单位: 摄氏度
频率, Hz	频率, 单位: 赫兹
磁芯损耗, w/m3	磁芯损耗, 单位: 瓦特每立方米
励磁波形	励磁波形类型 (正弦波、三角波、梯形波)
max_value	磁通密度最大值
min_value	磁通密度最小值
mean_value	磁通密度均值
std_dev	磁通密度标准差
peak_to_peak	幅值 (最大值与最小值之差)
skewness	偏度, 反映分布的不对称性
kurtosis	峰度, 反映分布的尖锐程度
total_energy	总能量 (频谱中所有频率成分的能量之和)
top_10_energy	前 10 个频率成分的能量之和
main_frequency	主频率 (能量最高的频率成分)
energy_distribution_std	频谱能量分布的标准差
gradient_rate	梯度变化率, 反映波形斜率的变化
zero_crossings	零交叉点, 波形穿越零点的次数
total_area	总面积, 磁通密度在一个周期内正负面积之和

解释: 对附件一特征提取后的材料四合一表格表头, 作为所有问题的基础数据

表 2: XGBoost 对负数预测修正方案对比

修正方法	XGBoost	MSE	MAE	RMSE	MAPE (%)
算术平均	训练集	175387188.4	8017.463383	13243.38282	22.13267769
	测试集	89998919.19	5874.405569	9486.776017	25.23193332
	误差幅度对比	0.513144	0.732701	0.716341	1.140031
	交叉验证	2048048505	19776.82696	45102.37324	27.02011086
中位数	训练集	175387830.6	8017.559934	13243.40706	22.13405613
	测试集	90002473.08	5875.153335	9486.963322	25.22555724
	误差幅度对比	0.513162588	0.732785708	0.716353675	1.139671694
	交叉验证	2048048505	19776.82696	45102.37324	27.02011086
几何平均	训练集	175393425.1	8018.418623	13243.61828	22.14826448
	测试集	90004611.31	5875.599173	9487.076015	25.2221741
	误差幅度对比	0.513158411	0.732762836	0.71635076	1.138787832
	交叉验证	2048048505	19776.82696	45102.37324	27.02011086

解释: 限制边界或者改变损失函数会导致模型无法收敛故需处理负值预测